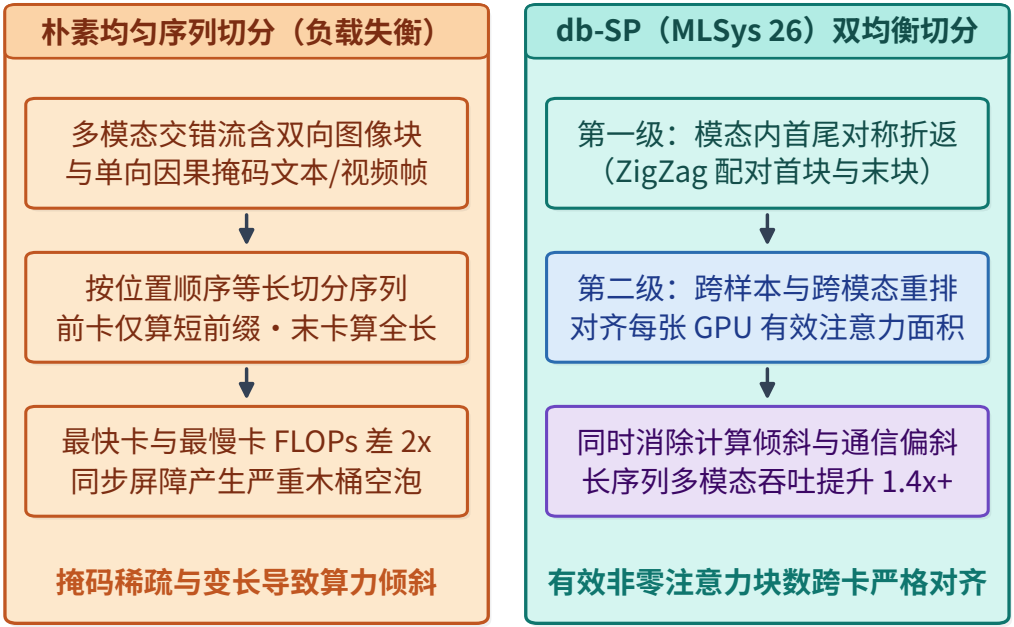
朴素均匀序列切分（负载失衡）
多模态交错流含双向图像块
与单向因果掩码文本/视频帧
按位置顺序等长切分序列
前卡仅算短前缀，末卡算全长
最快卡与最慢卡 FLOPs 差 2x
同步屏障产生严重木桶空泡
掩码稀疏与变长导致算力倾斜
db-SP（MLSys 26）双均衡切分
第一级：模态内首尾对称折返
（ZigZag 配对首块与末块）
第二级：跨样本与跨模态重排
对齐每张 GPU 有效注意力面积
同时消除计算倾斜与通信偏斜
长序列多模态吞吐提升 1.4x+
有效非零注意力块数跨卡严格对齐