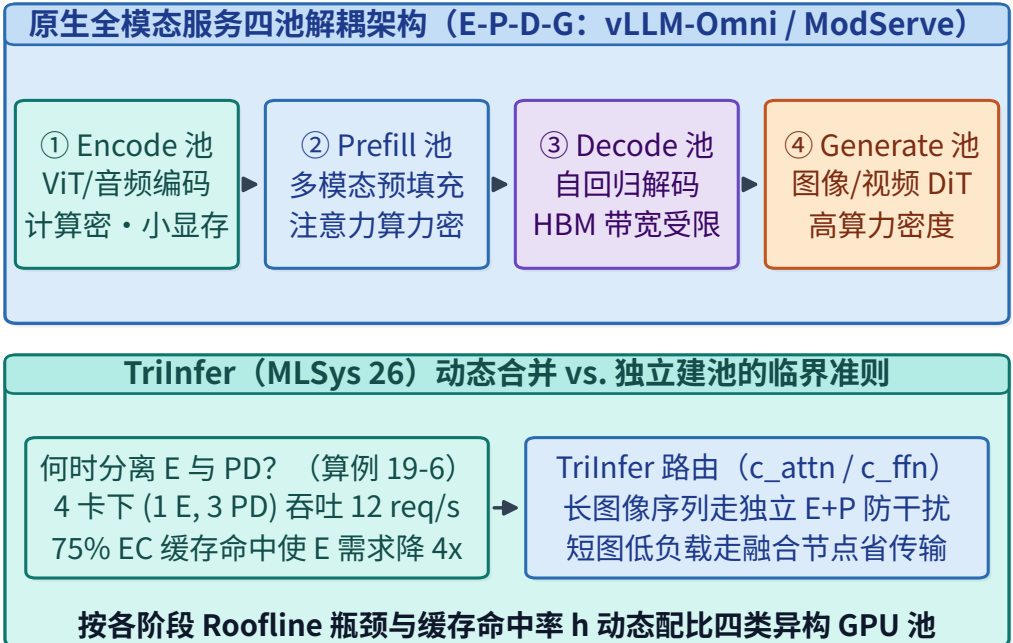
原生全模态服务四池解耦架构（E-P-D-G：vLLM-Omni / ModServe）
① Encode 池
ViT/音频编码
计算密・小显存
② Prefill 池
多模态预填充
注意力算力密
③ Decode 池
自回归解码
HBM 带宽受限
④ Generate 池
图像/视频 DiT
高算力密度
TriInfer（MLSys 26）动态合并 vs. 独立建池的临界准则
何时分离 E 与 PD？（算例 19-6）
4 卡下 (1 E, 3 PD) 吞吐 12 req/s
75% EC 缓存命中使 E 需求降 4x
TriInfer 路由（c_attn / c_ffn）
长图像序列走独立 E+P 防干扰
短图低负载走融合节点省传输
按各阶段 Roofline 瓶颈与缓存命中率 h 动态配比四类异构 GPU 池