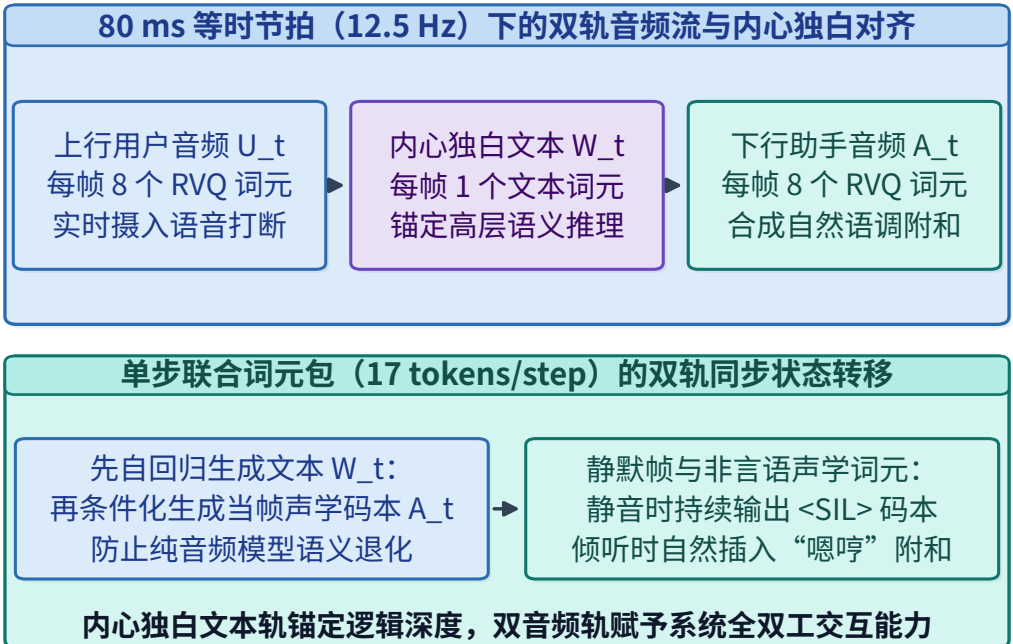
80 ms 等时节拍（12.5 Hz）下的双轨音频流与内心独白对齐
上行用户音频 U_t
每帧 8 个 RVQ 词元
实时摄入语音打断
内心独白文本 W_t
每帧 1 个文本词元
锚定高层语义推理
下行助手音频 A_t
每帧 8 个 RVQ 词元
合成自然语调附和
单步联合词元包（17 tokens/step）的双轨同步状态转移
先自回归生成文本 W_t：
再条件化生成当帧声学码本 A_t
防止纯音频模型语义退化
静默帧与非言语声学词元：
静音时持续输出 <SIL> 码本
倾听时自然插入“嗯哼”附和
内心独白文本轨锚定逻辑深度，双音频轨赋予系统全双工交互能力