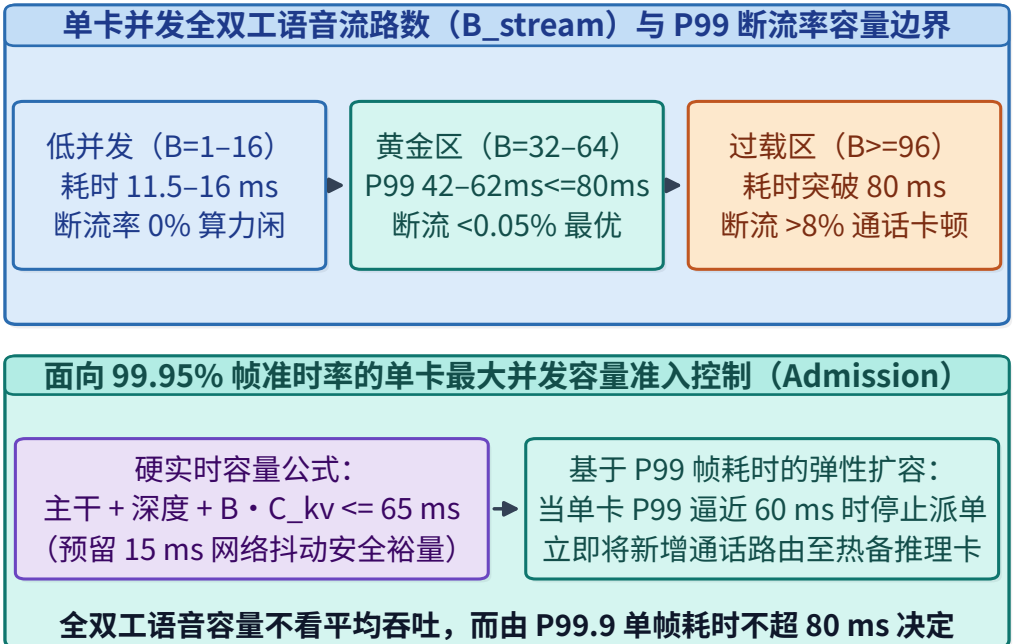
单卡并发全双工语音流路数（B_stream）与 P99 断流率容量边界
低并发（B=1–16）
耗时 11.5–16 ms
断流率 0% 算力闲
黄金区（B=32–64）
P99 42–62ms<=80ms
断流 <0.05% 最优
过载区（B>=96）
耗时突破 80 ms
断流 >8% 通话卡顿
面向 99.95% 帧准时率的单卡最大并发容量准入控制（Admission）
硬实时容量公式：
主干 + 深度 + B・C_kv <= 65 ms
（预留 15 ms 网络抖动安全裕量）
基于 P99 帧耗时的弹性扩容：
当单卡 P99 逼近 60 ms 时停止派单
立即将新增通话路由至热备推理卡
全双工语音容量不看平均吞吐，而由 P99.9 单帧耗时不超 80 ms 决定