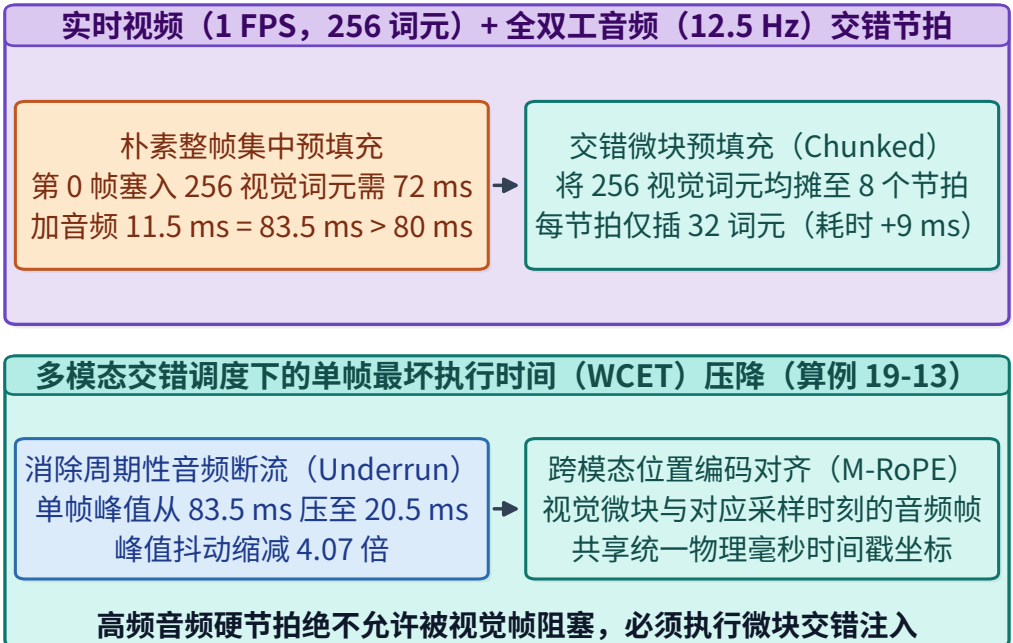
实时视频（1 FPS，256 词元）+ 全双工音频（12.5 Hz）交错节拍
朴素整帧集中预填充
第 0 帧塞入 256 视觉词元需 72 ms
加音频 11.5 ms = 83.5 ms > 80 ms
交错微块预填充（Chunked）
将 256 视觉词元均摊至 8 个节拍
每节拍仅插 32 词元（耗时 +9 ms）
多模态交错调度下的单帧最坏执行时间（WCET）压降（算例 19-13）
消除周期性音频断流（Underrun）
单帧峰值从 83.5 ms 压至 20.5 ms
峰值抖动缩减 4.07 倍
跨模态位置编码对齐（M-RoPE）
视觉微块与对应采样时刻的音频帧
共享统一物理毫秒时间戳坐标
高频音频硬节拍绝不允许被视觉帧阻塞，必须执行微块交错注入