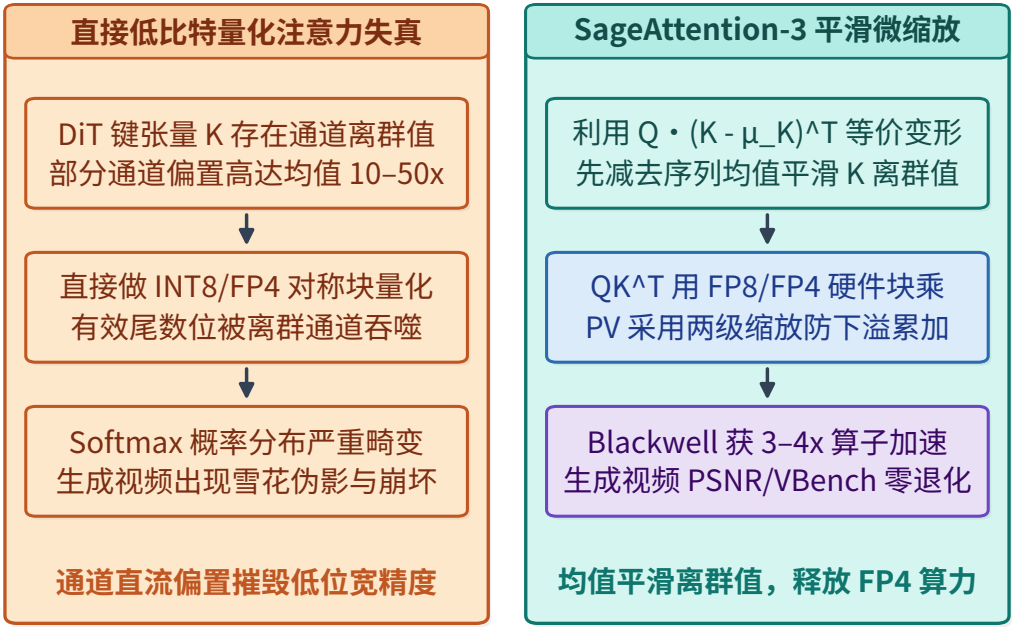
直接低比特量化注意力失真
DiT 键张量 K 存在通道离群值
部分通道偏置高达均值 10–50x
直接做 INT8/FP4 对称块量化
有效尾数位被离群通道吞噬
Softmax 概率分布严重畸变
生成视频出现雪花伪影与崩坏
通道直流偏置摧毁低位宽精度
SageAttention-3 平滑微缩放
利用 Q · (K - μ_K)^T 等价变形
先减去序列均值平滑 K 离群值
QK^T 用 FP8/FP4 硬件块乘
PV 采用两级缩放防下溢累加
Blackwell 获 3–4x 算子加速
生成视频 PSNR/VBench 零退化
均值平滑离群值，释放 FP4 算力