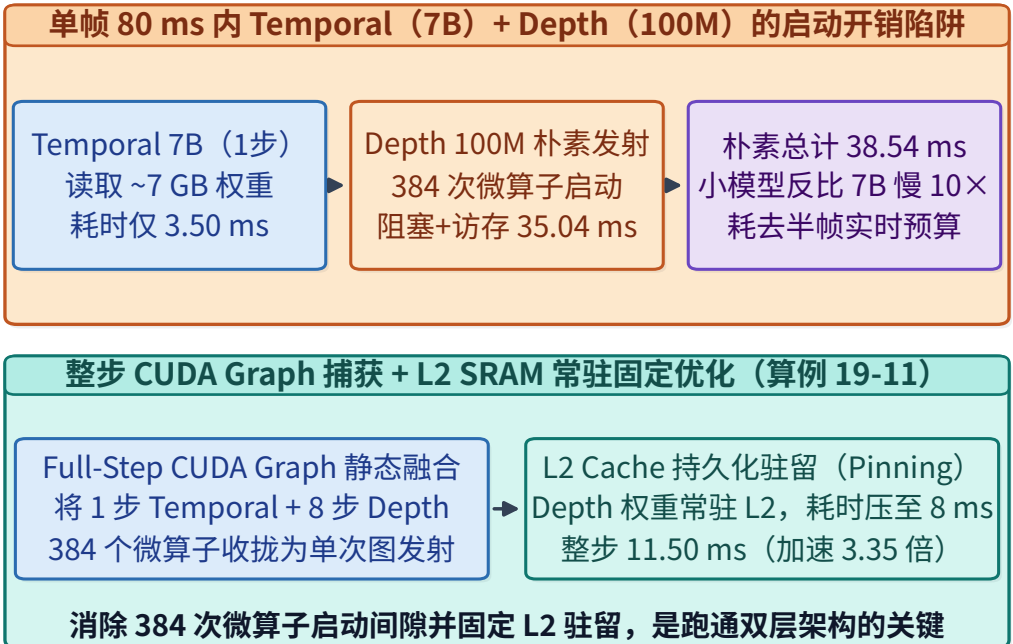
单帧 80 ms 内 Temporal（7B）+ Depth（100M）的启动开销陷阱
Temporal 7B（1步）
读取 ~7 GB 权重
耗时仅 3.50 ms
Depth 100M 朴素发射
384 次微算子启动
阻塞+访存 35.04 ms
朴素总计 38.54 ms
小模型反比 7B 慢 10×
耗去半帧实时预算
整步 CUDA Graph 捕获 + L2 SRAM 常驻固定优化（算例 19-11）
Full-Step CUDA Graph 静态融合
将 1 步 Temporal + 8 步 Depth
384 个微算子收拢为单次图发射
L2 Cache 持久化驻留（Pinning）
Depth 权重常驻 L2，耗时压至 8 ms
整步 11.50 ms（加速 3.35 倍）
消除 384 次微算子启动间隙并固定 L2 驻留，是跑通双层架构的关键