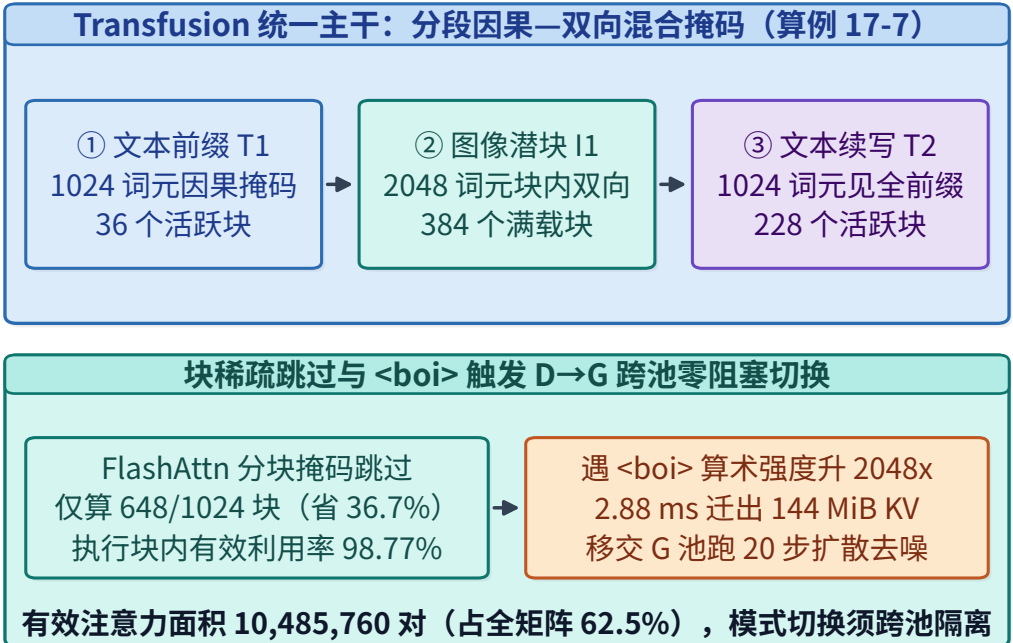
Transfusion 统一主干：分段因果—双向混合掩码（算例 17-7）
① 文本前缀 T1
1024 词元因果掩码
36 个活跃块
② 图像潜块 I1
2048 词元块内双向
384 个满载块
③ 文本续写 T2
1024 词元见全前缀
228 个活跃块
块稀疏跳过与 <boi> 触发 D→G 跨池零阻塞切换
FlashAttn 分块掩码跳过
仅算 648/1024 块（省 36.7%）
执行块内有效利用率 98.77%
遇 <boi> 算术强度升 2048x
2.88 ms 迁出 144 MiB KV
移交 G 池跑 20 步扩散去噪
有效注意力面积 10,485,760 对（占全矩阵 62.5%），模式切换须跨池隔离