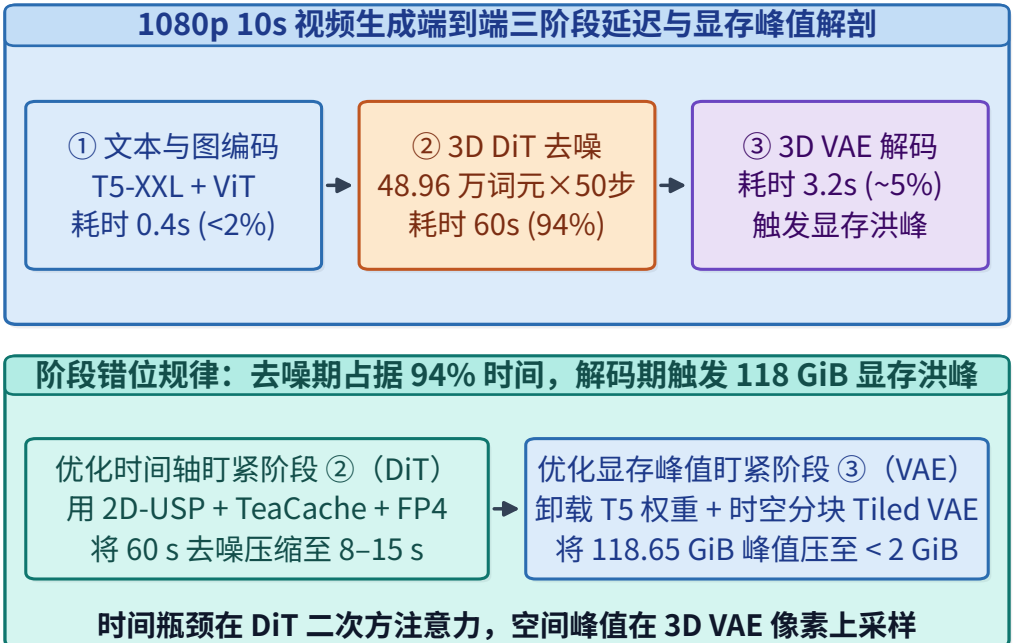
1080p 10s 视频生成端到端三阶段延迟与显存峰值解剖
① 文本与图编码
T5-XXL + ViT
耗时 0.4s (<2%)
② 3D DiT 去噪
48.96 万词元×50步
耗时 60s (94%)
③ 3D VAE 解码
耗时 3.2s (~5%)
触发显存洪峰
阶段错位规律：去噪期占据 94% 时间，解码期触发 118 GiB 显存洪峰
优化时间轴盯紧阶段 ②（DiT）
用 2D-USP + TeaCache + FP4
将 60 s 去噪压缩至 8–15 s
优化显存峰值盯紧阶段 ③（VAE）
卸载 T5 权重 + 时空分块 Tiled VAE
将 118.65 GiB 峰值压至 < 2 GiB
时间瓶颈在 DiT 二次方注意力，空间峰值在 3D VAE 像素上采样