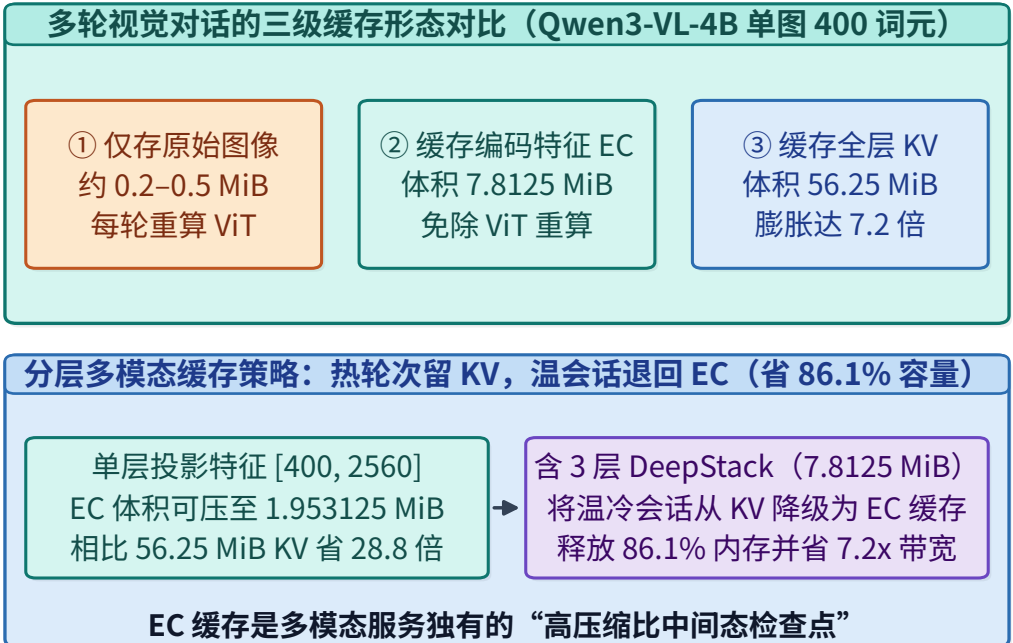
多轮视觉对话的三级缓存形态对比（Qwen3-VL-4B 单图 400 词元）
① 仅存原始图像
约 0.2–0.5 MiB
每轮重算 ViT
② 缓存编码特征 EC
体积 7.8125 MiB
免除 ViT 重算
③ 缓存全层 KV
体积 56.25 MiB
膨胀达 7.2 倍
分层多模态缓存策略：热轮次留 KV，温会话退回 EC（省 86.1% 容量）
单层投影特征 [400, 2560]
EC 体积可压至 1.953125 MiB
相比 56.25 MiB KV 省 28.8 倍
含 3 层 DeepStack（7.8125 MiB）
将温冷会话从 KV 降级为 EC 缓存
释放 86.1% 内存并省 7.2x 带宽
EC 缓存是多模态服务独有的“高压缩比中间态检查点”