面向硬实时截止期的视觉词元剪枝（VLA-Pruner）与早退

① 4 路高清相机输入
共 1,024 视觉词元
全算耗尽 150 ms

→

② 时空差分剪枝
复用静态背景 KV
仅留夹爪周 256 词元

→

③ 截止期感知早退
充裕跑 28 层，紧急时
第 18 层提前输出

将可变长视觉推理改造为硬实时确定性算子预算

Top-K 固定配额（非动态阈值）
强制保留词元数恒为 K = 256
后续层张量形状 100% 静态

→

静态形状兼容 CUDA Graph
视觉 Prefill 从 145 压至 38 ms
抖动 < 0.3 ms，成功率无损

用固定配额 Top-K 剪枝替代动态阈值，兼得加速与静态图确定性