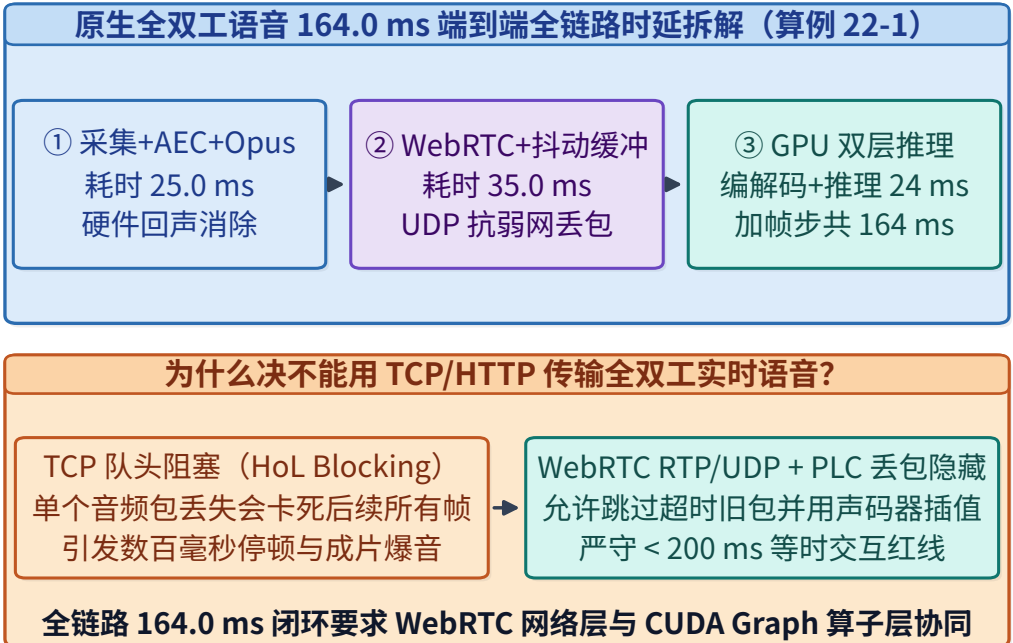
原生全双工语音 164.0 ms 端到端全链路时延拆解（算例 22-1）
① 采集+AEC+Opus
耗时 25.0 ms
硬件回声消除
② WebRTC+抖动缓冲
耗时 35.0 ms
UDP 抗弱网丢包
③ GPU 双层推理
编解码+推理 24 ms
加帧步共 164 ms
为什么决不能用 TCP/HTTP 传输全双工实时语音?
TCP 队头阻塞（HoL Blocking）
单个音频包丢失会卡死后续所有帧
引发数百毫秒停顿与成片爆音
WebRTC RTP/UDP + PLC 丢包隐藏
允许跳过超时旧包并用声码器插值
严守 < 200 ms 等时交互红线
全链路 164.0 ms 闭环要求 WebRTC 网络层与 CUDA Graph 算子层协同