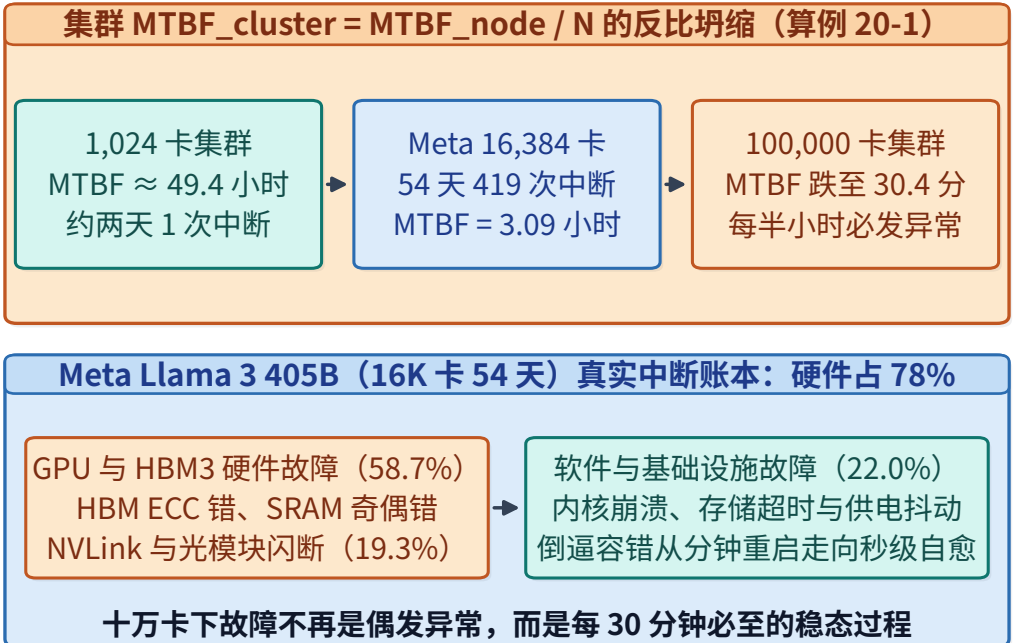
集群 MTBF_cluster = MTBF_node / N 的反比坍缩（算例 20-1）
1,024 卡集群
MTBF ≈ 49.4 小时
约两天 1 次中断
Meta 16,384 卡
54 天 419 次中断
MTBF = 3.09 小时
100,000 卡集群
MTBF 跌至 30.4 分
每半小时必发异常
Meta Llama 3 405B（16K 卡 54 天）真实中断账本：硬件占 78%
GPU 与 HBM3 硬件故障（58.7%）
HBM ECC 错、SRAM 奇偶错
NVLink 与光模块闪断（19.3%）
软件与基础设施故障（22.0%）
内核崩溃、存储超时与供电抖动
倒逼容错从分钟重启走向秒级自愈
十万卡下故障不再是偶发异常，而是每 30 分钟必至的稳态过程