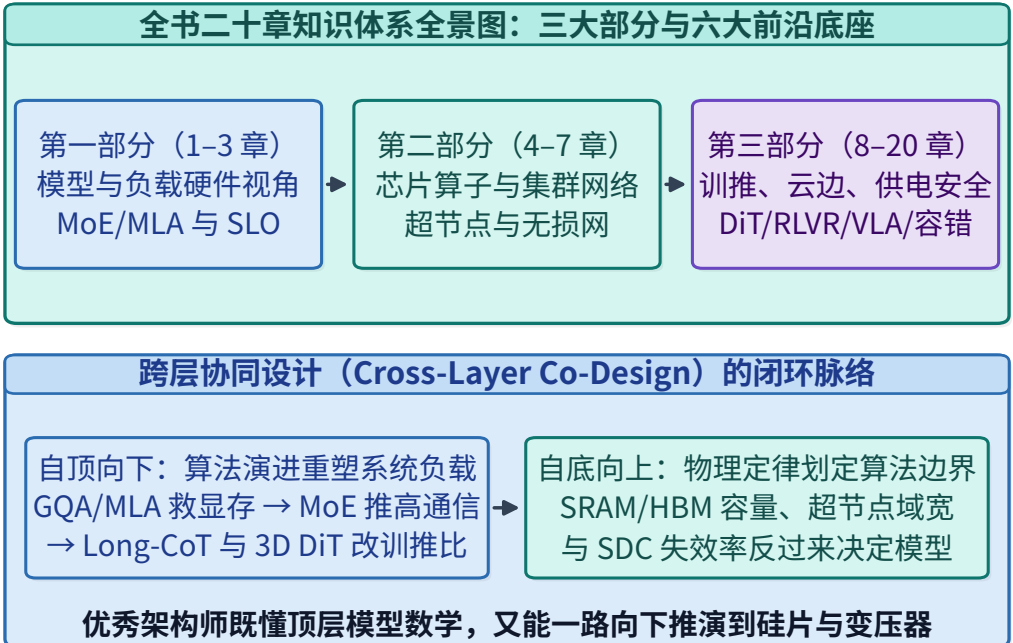
全书二十章知识体系全景图：三大部分与六大前沿底座
第一部分（1–3 章）
模型与负载硬件视角
MoE/MLA 与 SLO
第二部分（4–7 章）
芯片算子与集群网络
超节点与无损网
第三部分（8–20 章）
训推、云边、供电安全
DiT/RLVR/VLA/容错
跨层协同设计（Cross-Layer Co-Design）的闭环脉络
自顶向下：算法演进重塑系统负载
GQA/MLA 救显存 → MoE 推高通信
→ Long-CoT 与 3D DiT 改训推比
自底向上：物理定律划定算法边界
SRAM/HBM 容量、超节点域宽
与 SDC 失效率反过来决定模型
优秀架构师既懂顶层模型数学，又能一路向下推演到硅片与变压器