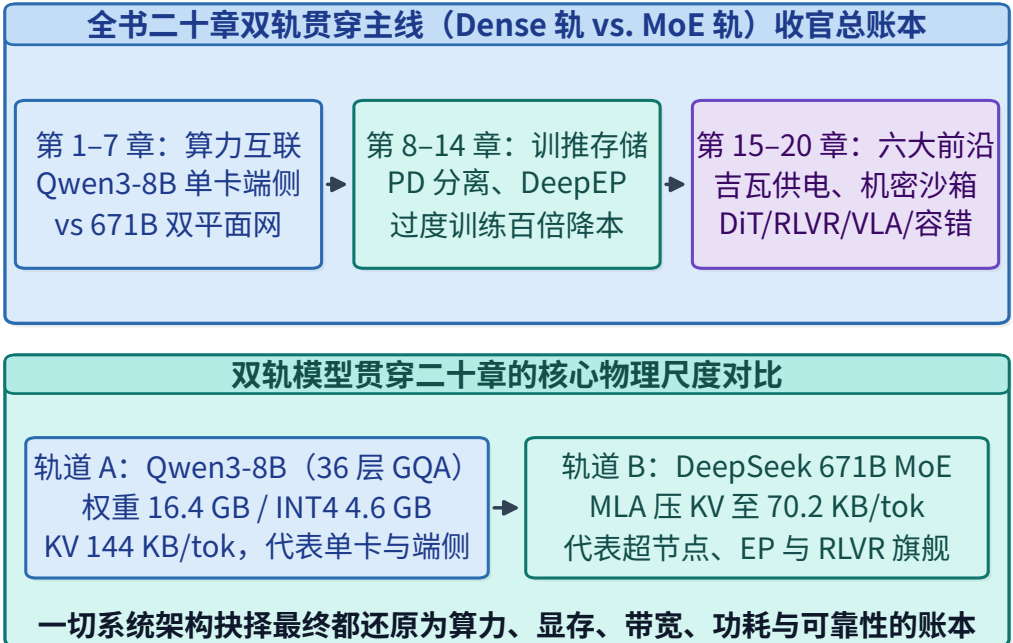
全书二十章双轨贯穿主线（Dense 轨 vs. MoE 轨）收官总账本
第 1–7 章：算力互联
Qwen3-8B 单卡端侧
vs 671B 双平面网
第 8–14 章：训推存储
PD 分离、DeepEP
过度训练百倍降本
第 15–20 章：六大前沿
吉瓦供电、机密沙箱
DiT/RLVR/VLA/容错
双轨模型贯穿二十章的核心物理尺度对比
轨道 A：Qwen3-8B（36 层 GQA）
权重 16.4 GB / INT4 4.6 GB
KV 144 KB/tok，代表单卡与端侧
轨道 B：DeepSeek 671B MoE
MLA 压 KV 至 70.2 KB/tok
代表超节点、EP 与 RLVR 旗舰
一切系统架构抉择最终都还原为算力、显存、带宽、功耗与可靠性的账本