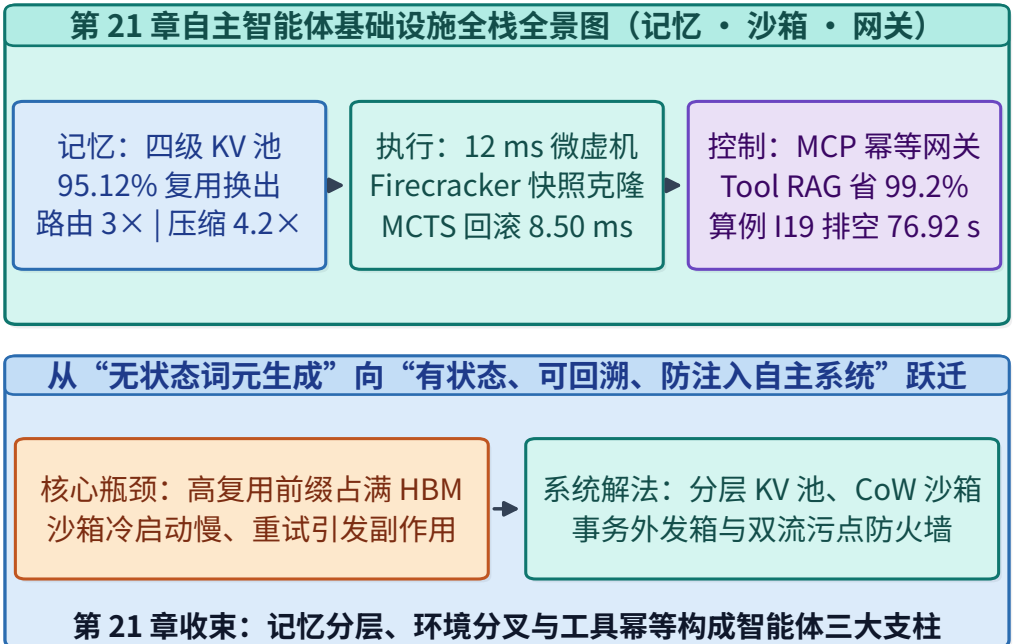
第 21 章自主智能体基础设施全栈全景图（记忆 · 沙箱 · 网关）
记忆：四级 KV 池
95.12% 复用换出
路由 3× | 压缩 4.2×
执行：12 ms 微虚机
Firecracker 快照克隆
MCTS 回滚 8.50 ms
控制：MCP 幂等网关
Tool RAG 省 99.2%
算例 I19 排空 76.92 s
从“无状态词元生成”向“有状态、可回溯、防注入自主系统”跃迁
核心瓶颈：高复用前缀占满 HBM
沙箱冷启动慢、重试引发副作用
系统解法：分层 KV 池、CoW 沙箱
事务外发箱与双流污点防火墙
第 21 章收束：记忆分层、环境分叉与工具幂等构成智能体三大支柱