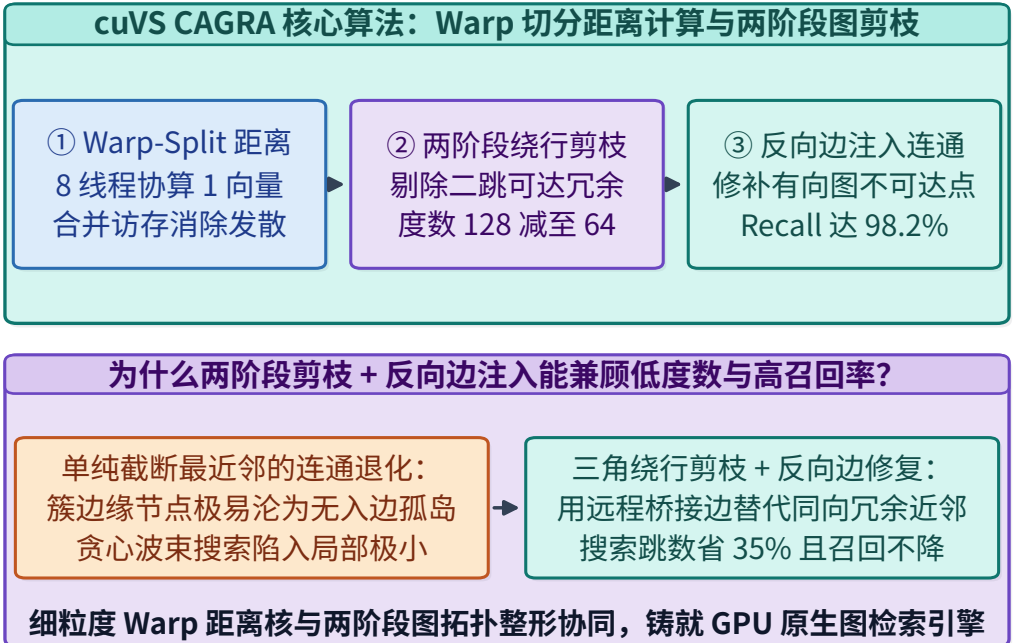
cuVS CAGRA 核心算法：Warp 切分距离计算与两阶段图剪枝
① Warp-Split 距离
8 线程协算 1 向量
合并访存消除发散
② 两阶段绕行剪枝
剔除二跳可达冗余
度数 128 减至 64
③ 反向边注入连通
修补有向图不可达点
Recall 达 98.2%
为什么两阶段剪枝 + 反向边注入能兼顾低度数与高召回率?
单纯截断最近邻的连通退化：
簇边缘节点极易沦为无入边孤岛
贪心波束搜索陷入局部极小
三角绕行剪枝 + 反向边修复：
用远程桥接边替代同向冗余近邻
搜索跳数省 35% 且召回不降
细粒度 Warp 距离核与两阶段图拓扑整形协同，铸就 GPU 原生图检索引擎