传统多级级联漏斗（DLRM）vs. 生成式推荐（Meta HSTU / OneRec）

① 传统级联漏斗
召回->粗排->精排
特征占 90% 耗时

② 算力碎片化困局
上百个异构小算子
MFU 长期低于 12%

③ 生成式序列转导
统一自回归 Token
MFU 跃升至 48%+

推荐系统从“带宽受限特征工程”向“算力扩展定律”的范式跃迁

级联 DLRM 的性能天花板：
增加参数仅增大稀疏表体积
难以带来长序列推理增益

HSTU 统一生成式序列架构：
将物品与动作交织为万级序列
遵循 Scaling Law 持续提效

把碎片化搜广推漏斗收敛为高算术强度序列转导器，充分释放 Tensor Core