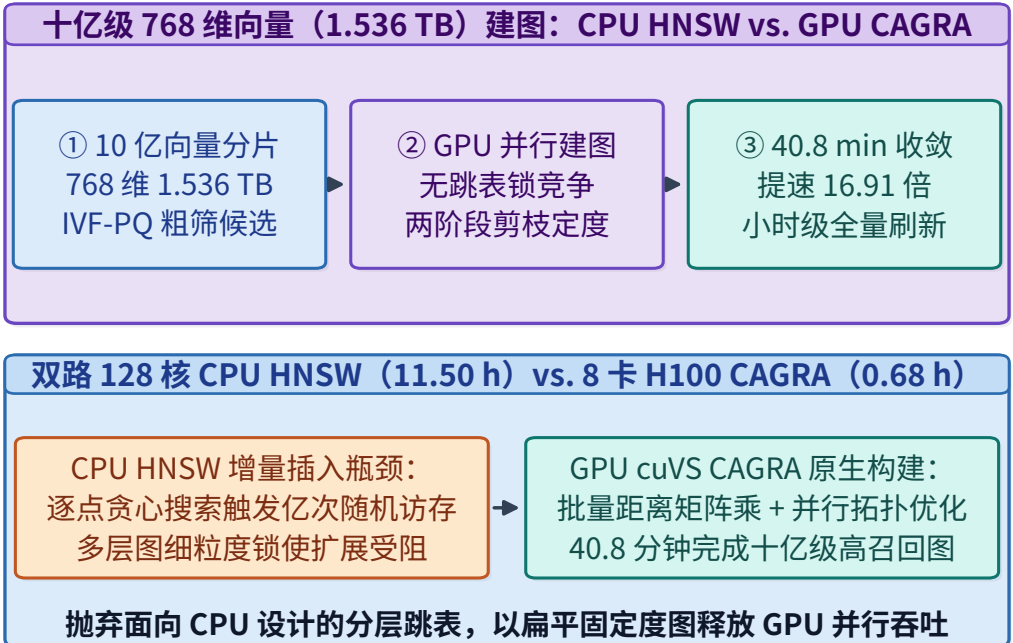
十亿级 768 维向量（1.536 TB）建图：CPU HNSW vs. GPU CAGRA
① 10 亿向量分片
768 维 1.536 TB
IVF-PQ 粗筛候选
② GPU 并行建图
无跳表锁竞争
两阶段剪枝定度
③ 40.8 min 收敛
提速 16.91 倍
小时级全量刷新
双路 128 核 CPU HNSW（11.50 h）vs. 8 卡 H100 CAGRA（0.68 h）
CPU HNSW 增量插入瓶颈：
逐点贪心搜索触发亿次随机访存
多层图细粒度锁使扩展受阻
GPU cuVS CAGRA 原生构建：
批量距离矩阵乘 + 并行拓扑优化
40.8 分钟完成十亿级高召回图
抛弃面向 CPU 设计的分层跳表，以扁平固定度图释放 GPU 并行吞吐