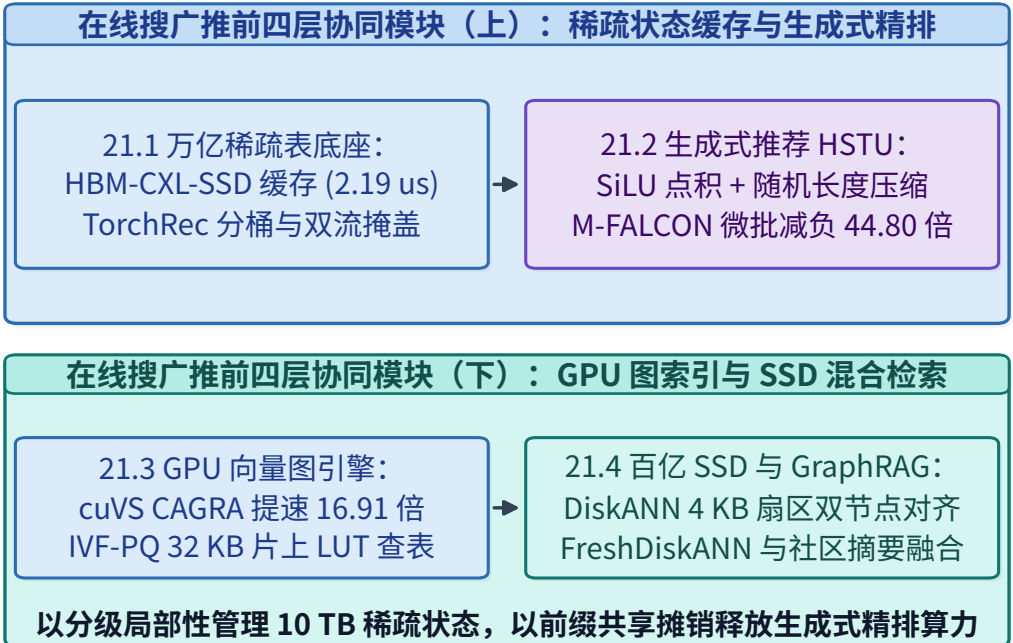
在线搜广推前四层协同模块（上）：稀疏状态缓存与生成式精排
21.1 万亿稀疏表底座：
HBM-CXL-SSD 缓存 (2.19 us)
TorchRec 分桶与双流掩盖
21.2 生成式推荐 HSTU：
SiLU 点积 + 随机长度压缩
M-FALCON 微批减负 44.80 倍
在线搜广推前四层协同模块（下）：GPU 图索引与 SSD 混合检索
21.3 GPU 向量图引擎：
cuVS CAGRA 提速 16.91 倍
IVF-PQ 32 KB 片上 LUT 查表
21.4 百亿 SSD 与 GraphRAG：
DiskANN 4 KB 扇区双节点对齐
FreshDiskANN 与社区摘要融合
以分级局部性管理 10 TB 稀疏状态，以前缀共享摊销释放生成式精排算力