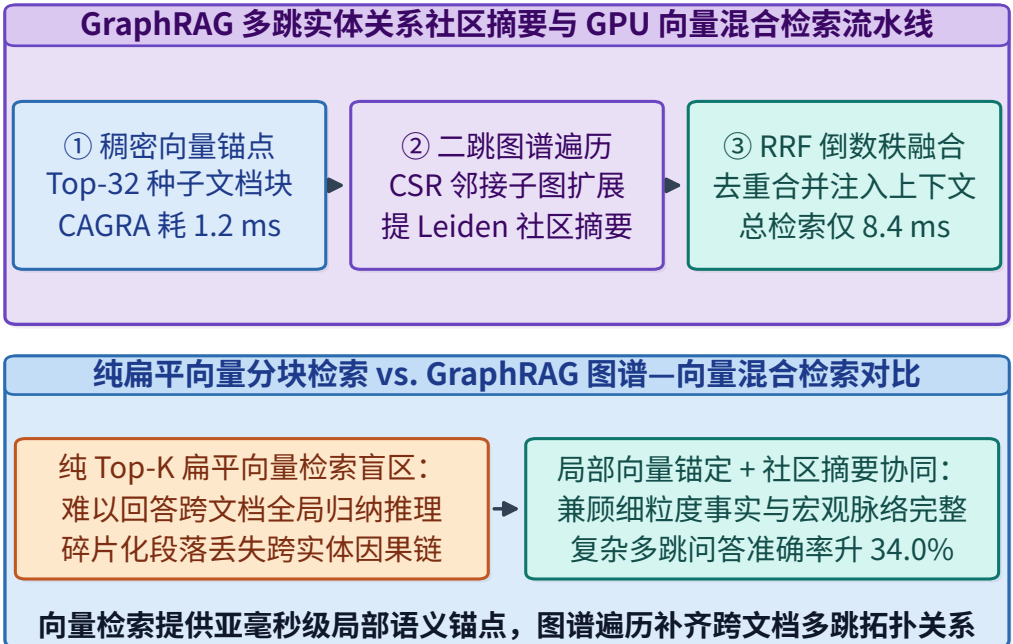
GraphRAG 多跳实体关系社区摘要与 GPU 向量混合检索流水线
① 稠密向量锚点
Top-32 种子文档块
CAGRA 耗 1.2 ms
② 二跳图谱遍历
CSR 邻接子图扩展
提 Leiden 社区摘要
③ RRF 倒数秩融合
去重合并注入上下文
总检索仅 8.4 ms
纯扁平向量分块检索 vs. GraphRAG 图谱—向量混合检索对比
纯 Top-K 扁平向量检索盲区：
难以回答跨文档全局归纳推理
碎片化段落丢失跨实体因果链
局部向量锚定 + 社区摘要协同：
兼顾细粒度事实与宏观脉络完整
复杂多跳问答准确率升 34.0%
向量检索提供亚毫秒级局部语义锚点，图谱遍历补齐跨文档多跳拓扑关系