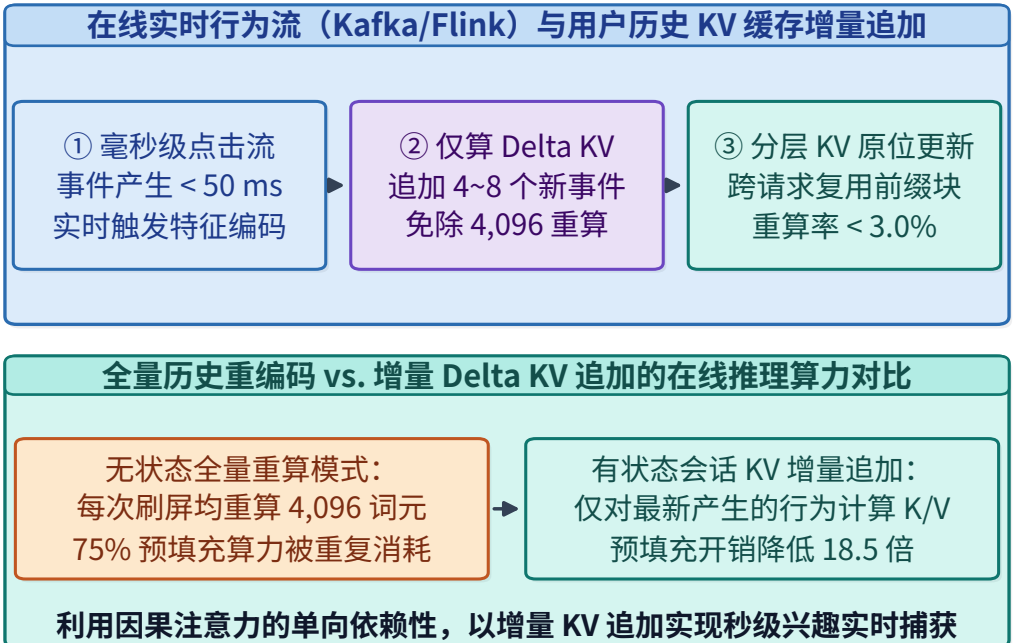
在线实时行为流（Kafka/Flink）与用户历史 KV 缓存增量追加
① 毫秒级点击流
事件产生 < 50 ms
实时触发特征编码
② 仅算 Delta KV
追加 4~8 个新事件
免除 4,096 重算
③ 分层 KV 原位更新
跨请求复用前缀块
重算率 < 3.0%
全量历史重编码 vs. 增量 Delta KV 追加的在线推理算力对比
无状态全量重算模式：
每次刷屏均重算 4,096 词元
75% 预填充算力被重复消耗
有状态会话 KV 增量追加：
仅对最新产生的行为计算 K/V
预填充开销降低 18.5 倍
利用因果注意力的单向依赖性，以增量 KV 追加实现秒级兴趣实时捕获