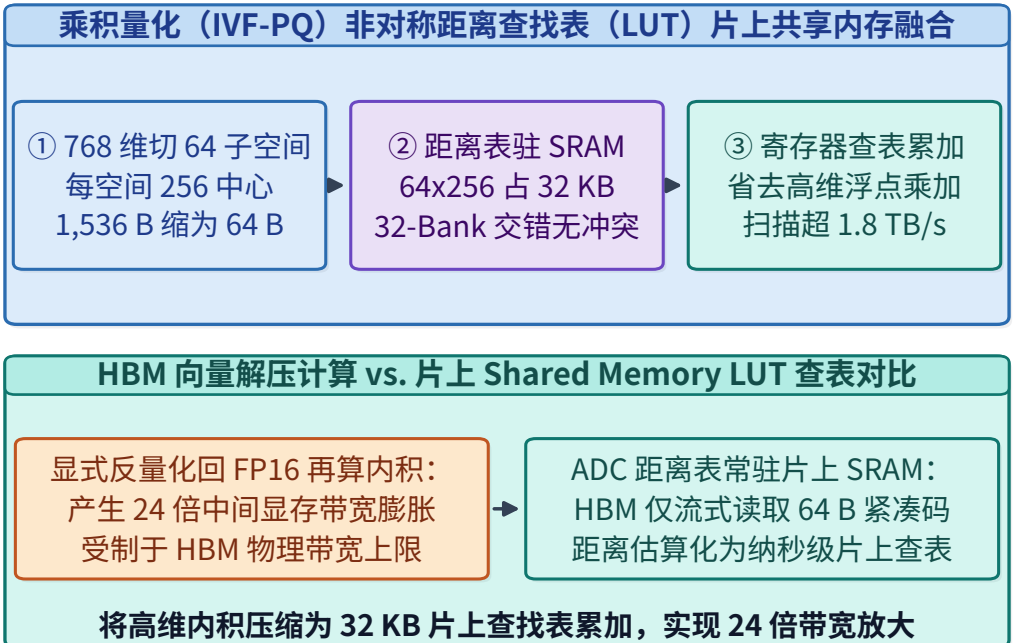
乘积量化（IVF-PQ）非对称距离查找表（LUT）片上共享内存融合
① 768 维切 64 子空间
每空间 256 中心
1,536 B 缩为 64 B
② 距离表驻 SRAM
64x256 占 32 KB
32-Bank 交错无冲突
③ 寄存器查表累加
省去高维浮点乘加
扫描超 1.8 TB/s
HBM 向量解压计算 vs. 片上 Shared Memory LUT 查表对比
显式反量化回 FP16 再算内积：
产生 24 倍中间显存带宽膨胀
受制于 HBM 物理带宽上限
ADC 距离表常驻片上 SRAM：
HBM 仅流式读取 64 B 紧凑码
距离估算化为纳秒级片上查表
将高维内积压缩为 32 KB 片上查找表累加，实现 24 倍带宽放大