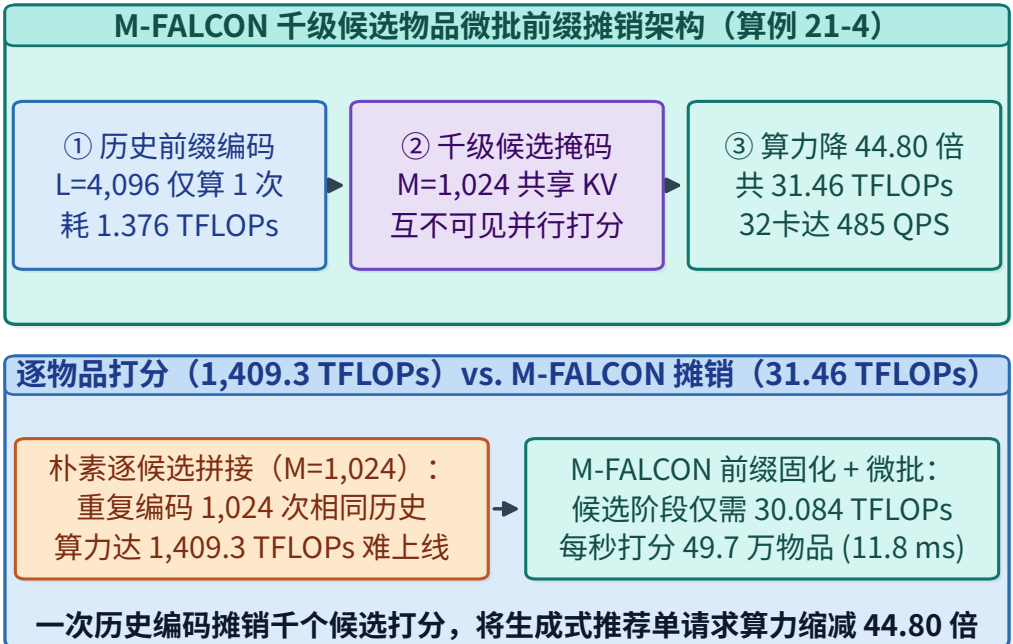
M-FALCON 千级候选物品微批前缀摊销架构（算例 21-4）
① 历史前缀编码
L=4,096 仅算 1 次
耗 1.376 TFLOPs
② 千级候选掩码
M=1,024 共享 KV
互不可见并行打分
③ 算力降 44.80 倍
共 31.46 TFLOPs
32卡达 485 QPS
逐物品打分（1,409.3 TFLOPs）vs. M-FALCON 摊销（31.46 TFLOPs）
朴素逐候选拼接（M=1,024）：
重复编码 1,024 次相同历史
算力达 1,409.3 TFLOPs 难上线
M-FALCON 前缀固化 + 微批：
候选阶段仅需 30.084 TFLOPs
每秒打分 49.7 万物品 (11.8 ms)
一次历史编码摊销千个候选打分，将生成式推荐单请求算力缩减 44.80 倍