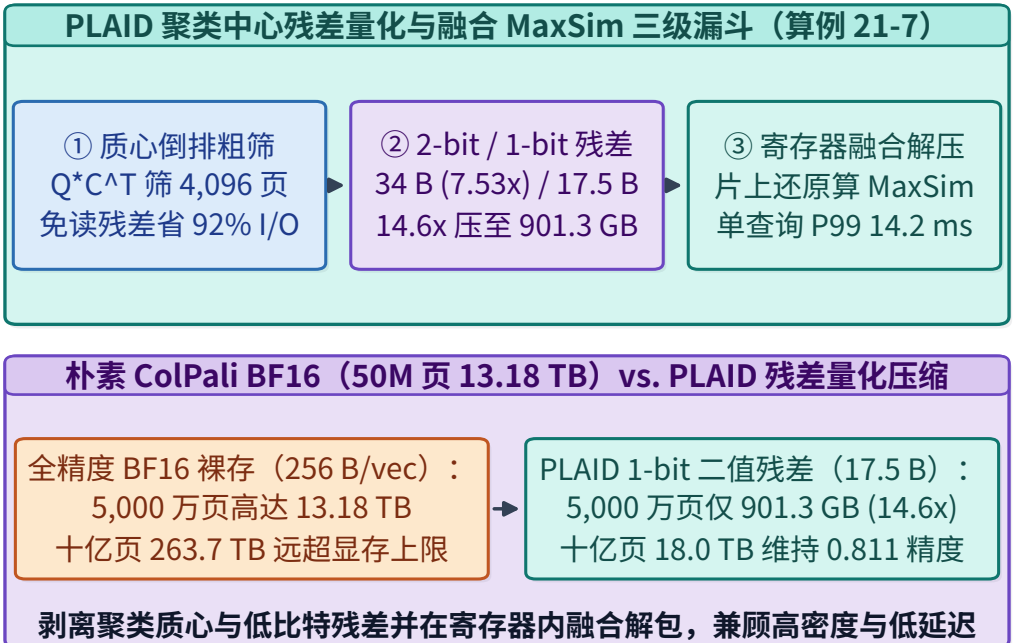
PLAID 聚类中心残差量化与融合 MaxSim 三级漏斗（算例 21-7）
① 质心倒排粗筛
Q*C^T 筛 4,096 页
免读残差省 92% I/O
② 2-bit / 1-bit 残差
34 B (7.53x) / 17.5 B
14.6x 压至 901.3 GB
③ 寄存器融合解压
片上还原算 MaxSim
单查询 P99 14.2 ms
朴素 ColPali BF16（50M 页 13.18 TB）vs. PLAID 残差量化压缩
全精度 BF16 裸存（256 B/vec）：
5,000 万页高达 13.18 TB
十亿页 263.7 TB 远超显存上限
PLAID 1-bit 二值残差（17.5 B）：
5,000 万页仅 901.3 GB (14.6x)
十亿页 18.0 TB 维持 0.811 精度
剥离聚类质心与低比特残差并在寄存器内融合解包，兼顾高密度与低延迟