搜广推与向量检索 GPU 机队全链路 SLA（50 ms）预算拆解

① 多路向量召回
CAGRA + DiskANN
耗时 3.5 ms (7%)

② 三级稀疏查表
HBM+CXL+GDS
耗时 2.5 ms (5%)

③ HSTU 微批精排
千级候选并行打分
11.8 ms (共 17.8 ms)

搜广推机队从 CPU+级联小模型向“全栈 GPU 生成式底座”演进

传统万台 CPU 检索 + 级联卡池：
跨机房 RPC 序列化耗去 25 ms
机柜功耗高且利用率不足 15%

同机柜 GPU 检索 + HSTU 部署：
端到端 P99 仅 17.8 ms (< 50 ms)
单瓦特 GMV 产出提升 3.4 倍

打通向量召回、三级稀疏查表与生成式精排，重塑互联网核心现金流底座