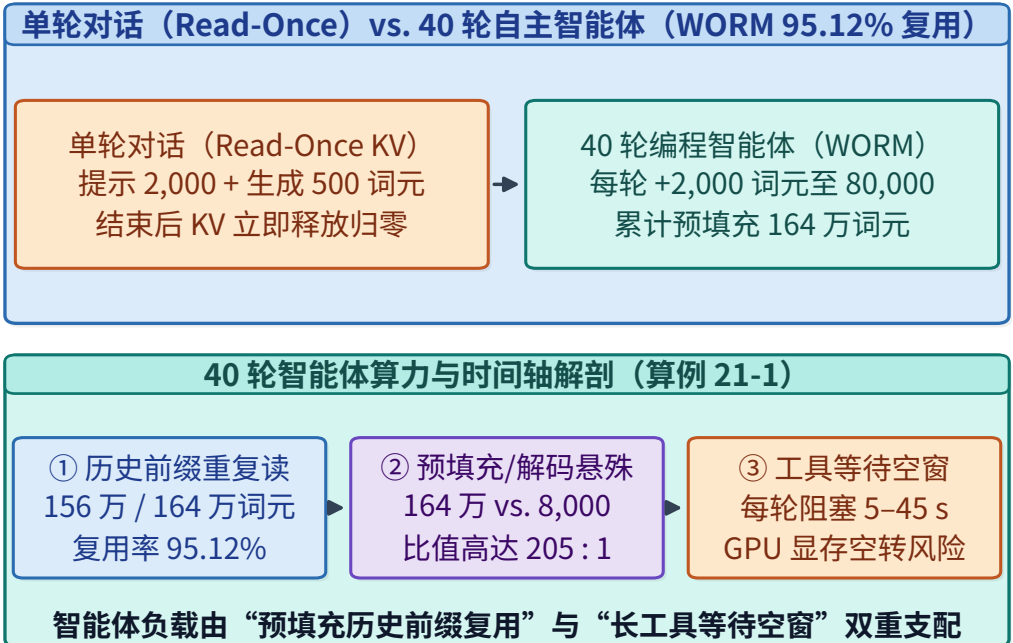
单轮对话（Read-Once）vs. 40 轮自主智能体（WORM 95.12% 复用）
单轮对话（Read-Once KV）
提示 2,000 + 生成 500 词元
结束后 KV 立即释放归零
40 轮编程智能体（WORM）
每轮 +2,000 词元至 80,000
累计预填充 164 万词元
40 轮智能体算力与时间轴解剖（算例 21-1）
① 历史前缀重复读
156 万 / 164 万词元
复用率 95.12%
② 预填充/解码悬殊
164 万 vs. 8,000
比值高达 205 : 1
③ 工具等待空窗
每轮阻塞 5–45 s
GPU 显存空转风险
智能体负载由“预填充历史前缀复用”与“长工具等待空窗”双重支配