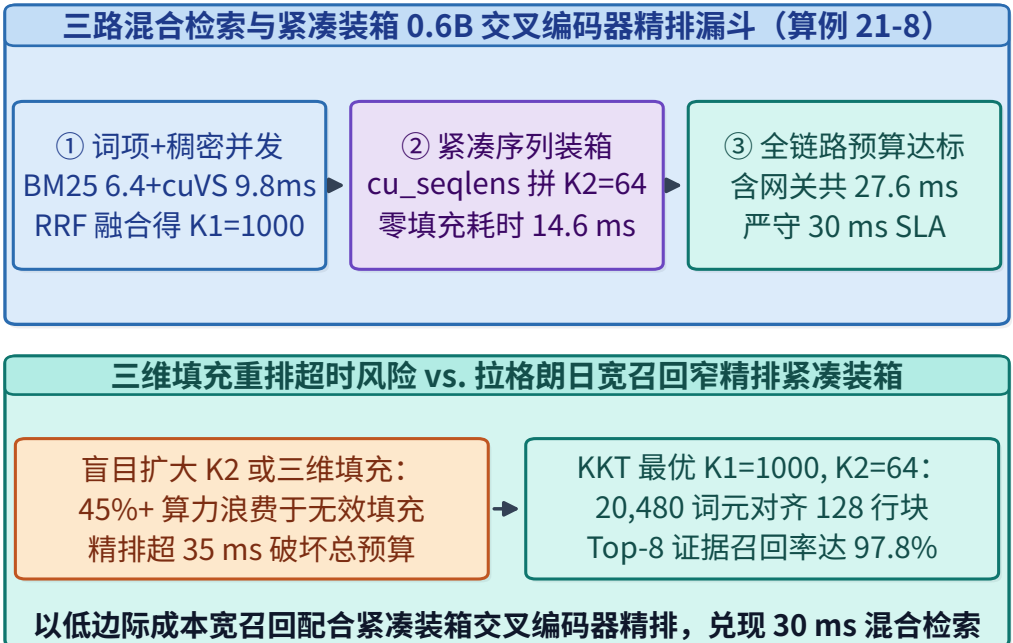
三路混合检索与紧凑装箱 0.6B 交叉编码器精排漏斗（算例 21-8）
① 词项+稠密并发
BM25 6.4+cuVS 9.8ms
RRF 融合得 K1=1000
② 紧凑序列装箱
cu_seqlens 拼 K2=64
零填充耗时 14.6 ms
③ 全链路预算达标
含网关共 27.6 ms
严守 30 ms SLA
三维填充重排超时风险 vs. 拉格朗日宽召回窄精排紧凑装箱
盲目扩大 K2 或三维填充：
45%+ 算力浪费于无效填充
精排超 35 ms 破坏总预算
KKT 最优 K1=1000, K2=64：
20,480 词元对齐 128 行块
Top-8 证据召回率达 97.8%
以低边际成本宽召回配合紧凑装箱交叉编码器精排，兑现 30 ms 混合检索