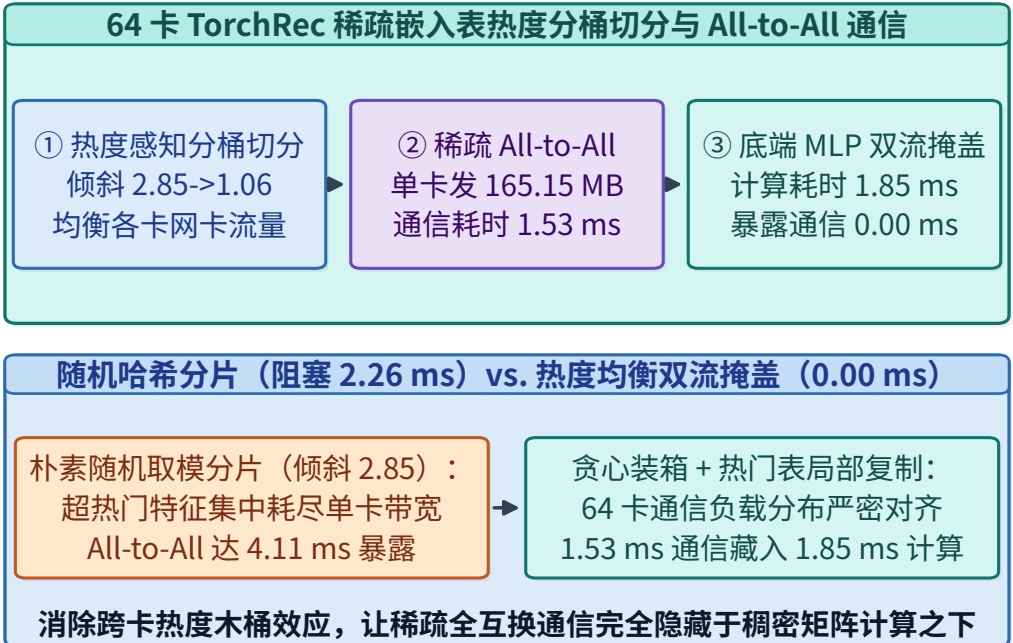
64 卡 TorchRec 稀疏嵌入表热度分桶切分与 All-to-All 通信
① 热度感知分桶切分
倾斜 2.85->1.06
均衡各卡网卡流量
② 稀疏 All-to-All
单卡发 165.15 MB
通信耗时 1.53 ms
③ 底端 MLP 双流掩盖
计算耗时 1.85 ms
暴露通信 0.00 ms
随机哈希分片（阻塞 2.26 ms）vs. 热度均衡双流掩盖（0.00 ms）
朴素随机取模分片（倾斜 2.85）：
超热门特征集中耗尽单卡带宽
All-to-All 达 4.11 ms 暴露
贪心装箱 + 热门表局部复制：
64 卡通信负载分布严密对齐
1.53 ms 通信藏入 1.85 ms 计算
消除跨卡热度木桶效应，让稀疏全互换通信完全隐藏于稠密矩阵计算之下