Meta HSTU 非归一化点积聚合注意力与随机序列长度压缩

① 摒弃 Softmax 归一
SiLU 点积聚合
保留活跃度幅值

② 随机序列长度压缩
8,192->5,410 词元
近期全留+远期采样

③ 二次方算力减半
注意力省 56.2%
精度损 < 0.04%

为什么推荐序列必须用非归一化点积注意力替代标准 Softmax?

标准 Softmax 概率归一缺陷：
强行将总权重归一为 1.0
抹杀重度与冷启动用户强度差

SiLU 点积 + 融合内核优势：
省去行级最大值与指数和同步
单核吞吐较标准提升 1.45 倍

非归一化点积兼顾推荐偏好幅值表达与片上核融合效率，SL 削减过半算力