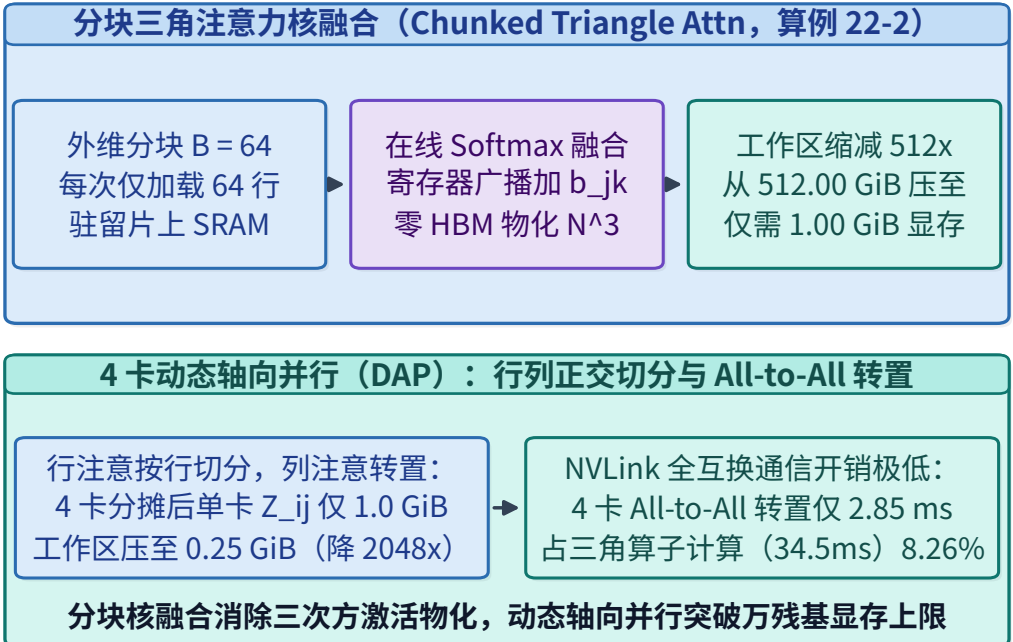
分块三角注意力核融合（Chunked Triangle Attn，算例 22-2）
外维分块 B = 64
每次仅加载 64 行
驻留片上 SRAM
在线 Softmax 融合
寄存器广播加 b_jk
零 HBM 物化 N^3
工作区缩减 512x
从 512.00 GiB 压至
仅需 1.00 GiB 显存
4 卡动态轴向并行（DAP）：行列正交切分与 All-to-All 转置
行注意按行切分，列注意转置：
4 卡分摊后单卡 Z_ij 仅 1.0 GiB
工作区压至 0.25 GiB（降 2048x）
NVLink 全互换通信开销极低：
4 卡 All-to-All 转置仅 2.85 ms
占三角算子计算（34.5ms）8.26%
分块核融合消除三次方激活物化，动态轴向并行突破万残基显存上限