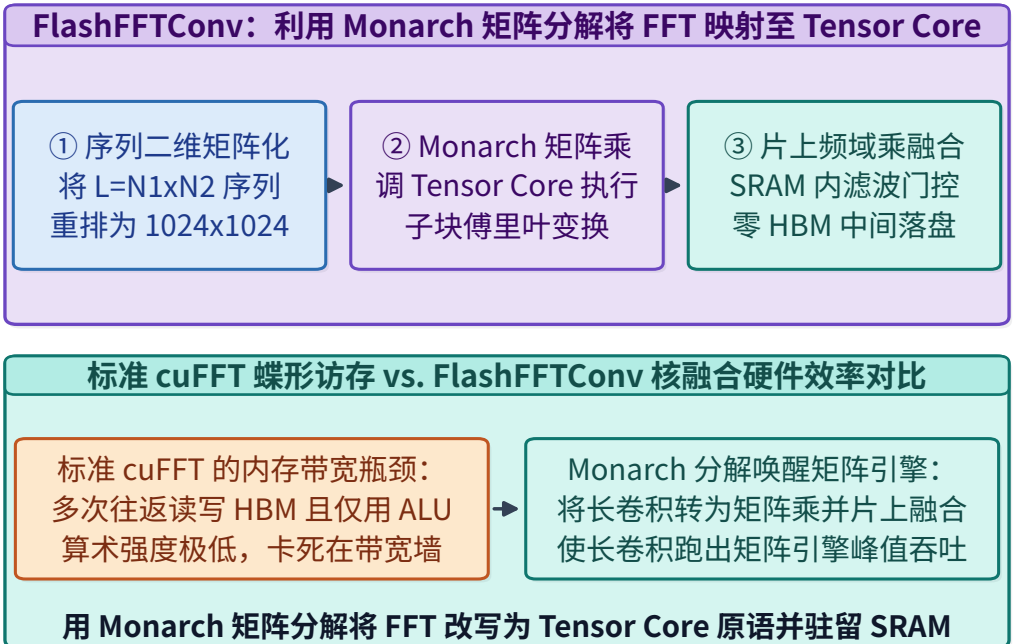
FlashFFTConv：利用 Monarch 矩阵分解将 FFT 映射至 Tensor Core
① 序列二维矩阵化
将 L=N1xN2 序列
重排为 1024x1024
② Monarch 矩阵乘
调 Tensor Core 执行
子块傅里叶变换
③ 片上频域乘融合
SRAM 内滤波门控
零 HBM 中间落盘
标准 cuFFT 蝶形访存 vs. FlashFFTConv 核融合硬件效率对比
标准 cuFFT 的内存带宽瓶颈：
多次往返读写 HBM 且仅用 ALU
算术强度极低，卡死在带宽墙
Monarch 分解唤醒矩阵引擎：
将长卷积转为矩阵乘并片上融合
使长卷积跑出矩阵引擎峰值吞吐
用 Monarch 矩阵分解将 FFT 改写为 Tensor Core 原语并驻留 SRAM