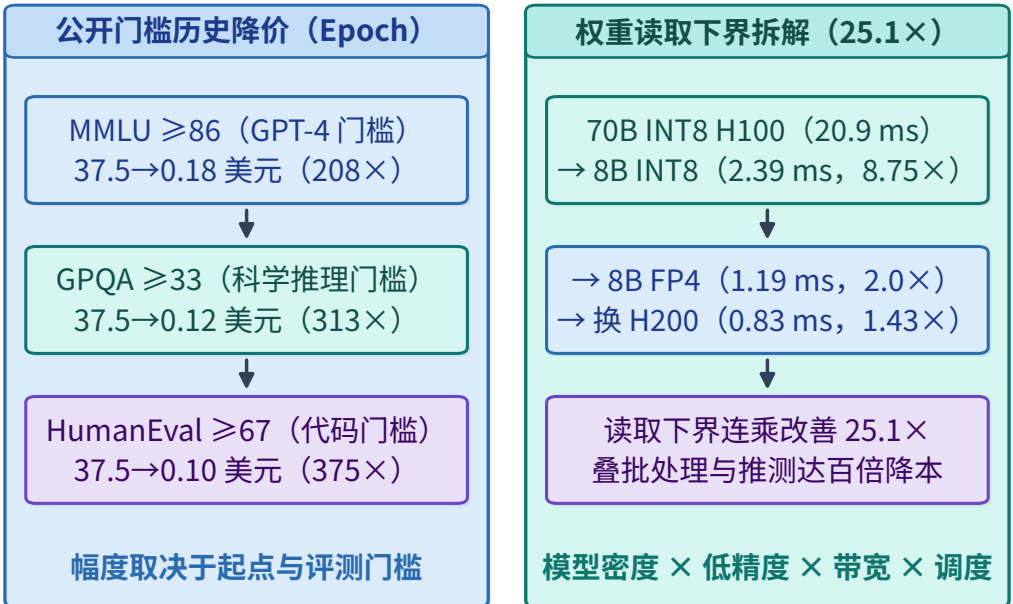
公开门槛历史降价（Epoch）
MMLU ⩾86（GPT-4 门槛）
37.5→0.18 美元（208×）
GPQA ⩾33（科学推理门槛）
37.5→0.12 美元（313×）
HumanEval ⩾67（代码门槛）
37.5→0.10 美元（375×）
幅度取决于起点与评测门槛
权重读取下界拆解（25.1×）
70B INT8 H100（20.9 ms）
→ 8B INT8（2.39 ms，8.75×）
→ 8B FP4（1.19 ms，2.0×）
→ 换 H200（0.83 ms，1.43×）
读取下界连乘改善 25.1×
叠批处理与推测达百倍降本
模型密度 × 低精度 × 带宽 × 调度