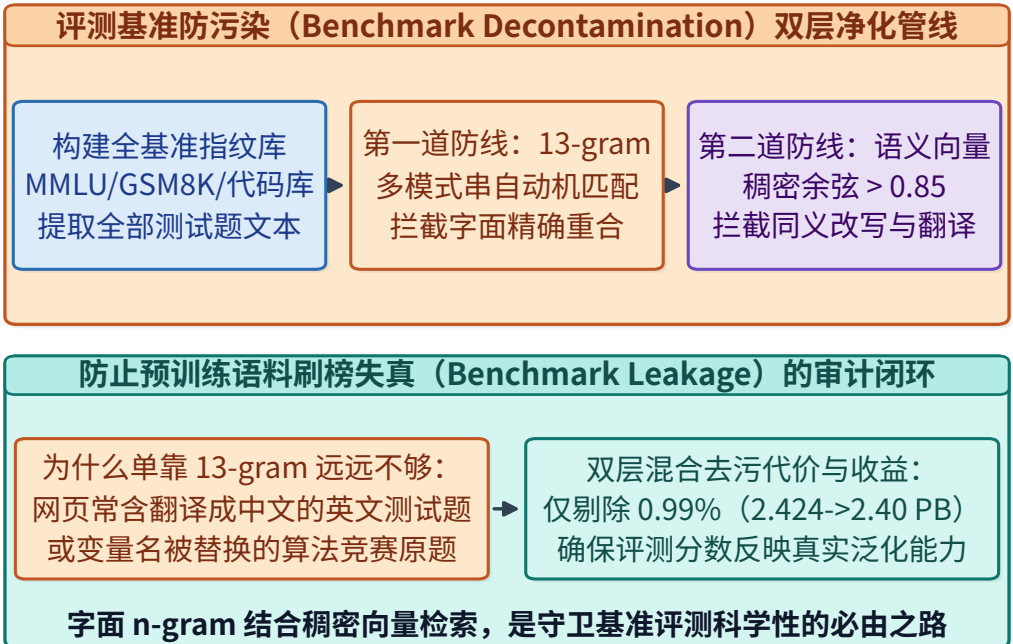
评测基准防污染（Benchmark Decontamination）双层净化管线
构建全基准指纹库
MMLU/GSM8K/代码库
提取全部测试题文本
第一道防线：13-gram
多模式串自动机匹配
拦截字面精确重合
第二道防线：语义向量
稠密余弦 > 0.85
拦截同义改写与翻译
防止预训练语料刷榜失真（Benchmark Leakage）的审计闭环
为什么单靠 13-gram 远远不够：
网页常含翻译成中文的英文测试题
或变量名被替换的算法竞赛原题
双层混合去污代价与收益：
仅剔除 0.99%（2.424->2.40 PB）
确保评测分数反映真实泛化能力
字面 n-gram 结合稠密向量检索，是守卫基准评测科学性的必由之路