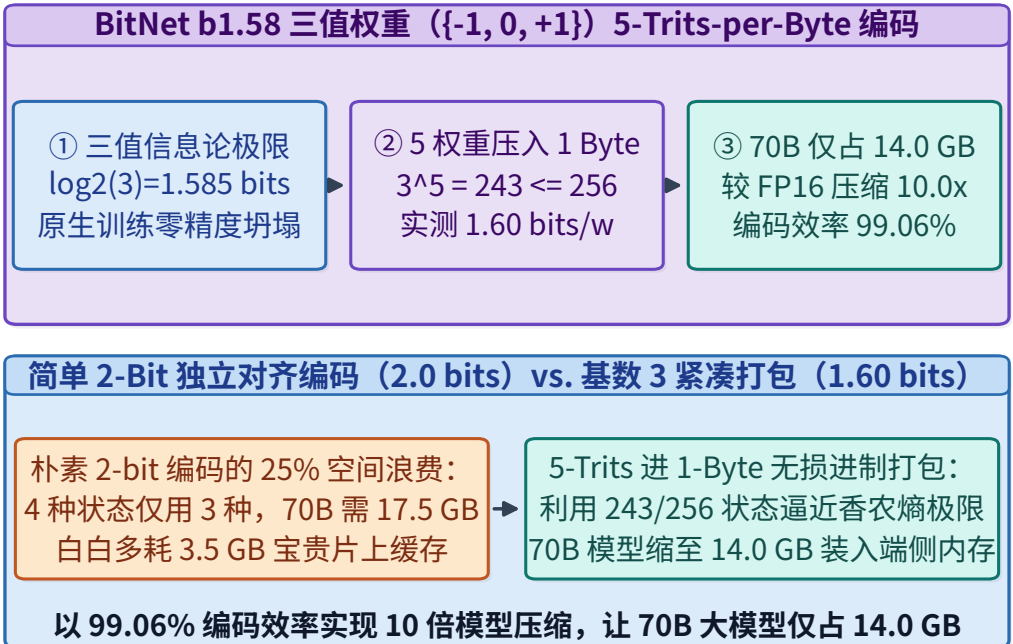
BitNet b1.58 三值权重（{-1, 0, +1}）5-Trits-per-Byte 编码
① 三值信息论极限
log2(3)=1.585 bits
原生训练零精度坍塌
② 5 权重压入 1 Byte
3^5 = 243 <= 256
实测 1.60 bits/w
③ 70B 仅占 14.0 GB
较 FP16 压缩 10.0x
编码效率 99.06%
简单 2-Bit 独立对齐编码（2.0 bits）vs. 基数 3 紧凑打包（1.60 bits）
朴素 2-bit 编码的 25% 空间浪费：
4 种状态仅用 3 种，70B 需 17.5 GB
白白多耗 3.5 GB 宝贵片上缓存
5-Trits 进 1-Byte 无损进制打包：
利用 243/256 状态逼近香农熵极限
70B 模型缩至 14.0 GB 装入端侧内存
以 99.06% 编码效率实现 10 倍模型压缩，让 70B 大模型仅占 14.0 GB