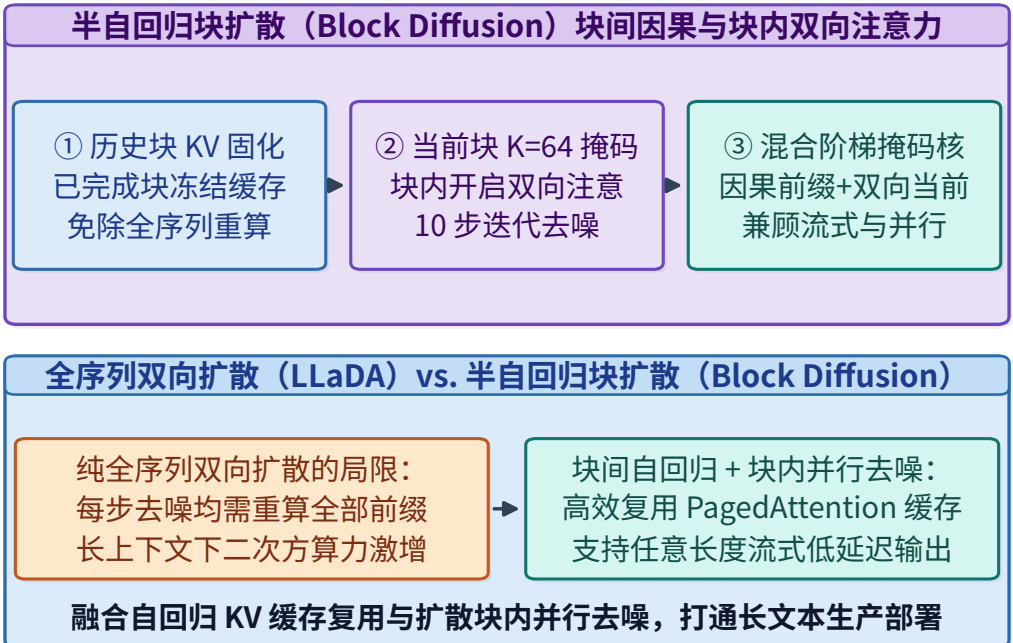
半自回归块扩散（Block Diffusion）块间因果与块内双向注意力
① 历史块 KV 固化
已完成块冻结缓存
免除全序列重算
② 当前块 K=64 掩码
块内开启双向注意
10 步迭代去噪
③ 混合阶梯掩码核
因果前缀+双向当前
兼顾流式与并行
全序列双向扩散（LLaDA）vs. 半自回归块扩散（Block Diffusion）
纯全序列双向扩散的局限：
每步去噪均需重算全部前缀
长上下文下二次方算力激增
块间自回归 + 块内并行去噪：
高效复用 PagedAttention 缓存
支持任意长度流式低延迟输出
融合自回归 KV 缓存复用与扩散块内并行去噪，打通长文本生产部署