BLT 三段式架构：局部字节编码—全局潜空间—局部字节解码

① 局部字节编码器
滑动窗口聚合字节
交叉注意汇入块表征

② 全局潜空间骨干
仅在稀疏 Patch 运行
承接 85% 参数容量

③ 局部字节解码器
结合潜向量恢复字节
输出仅 256 维投影

为什么 BLT 能同时兼顾字节级细粒度鲁棒性与词元级长上下文吞吐?

纯字节级自回归（ByT5）瓶颈：
序列长度膨胀 4.5 倍触发 O(L^2)
长文本下注意力延迟显著劣化

局部轻模块 + 全局重骨干解耦：
字节层仅做短距窗口特征提取
昂贵长程注意力运行在短 Patch

用非对称交叉注意力桥接原始字节流与高维潜空间，兼得无分词与高吞吐