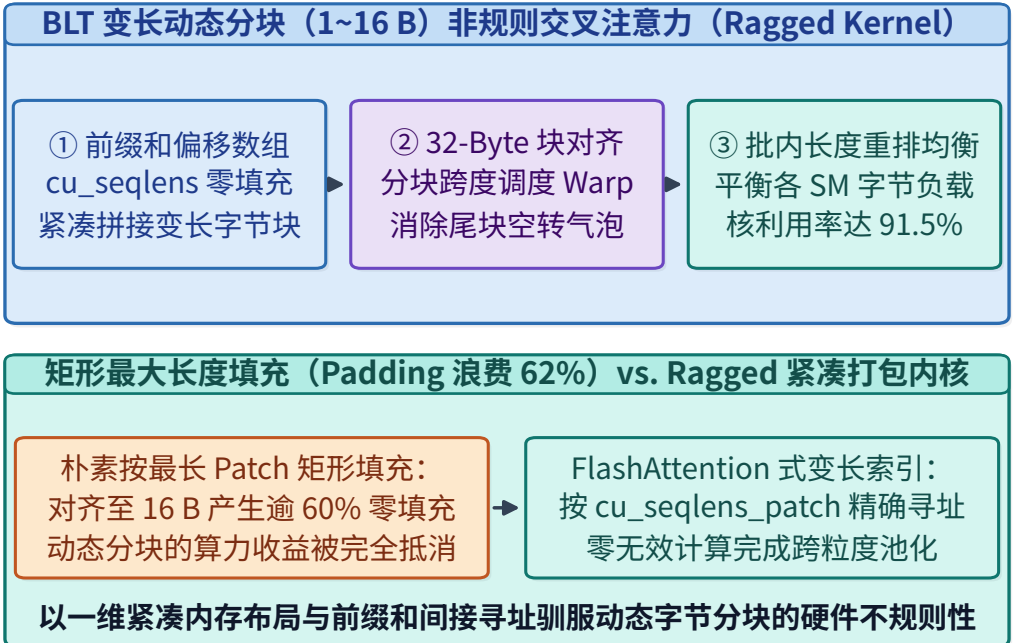
BLT 变长动态分块（1~16 B）非规则交叉注意力（Ragged Kernel）
① 前缀和偏移数组
cu_seqlens 零填充
紧凑拼接变长字节块
② 32-Byte 块对齐
分块跨度调度 Warp
消除尾块空转气泡
③ 批内长度重排均衡
平衡各 SM 字节负载
核利用率达 91.5%
矩形最大长度填充（Padding 浪费 62%）vs. Ragged 紧凑打包内核
朴素按最长 Patch 矩形填充：
对齐至 16 B 产生逾 60% 零填充
动态分块的算力收益被完全抵消
FlashAttention 式变长索引：
按 cu_seqlens_patch 精确寻址
零无效计算完成跨粒度池化
以一维紧凑内存布局与前缀和间接寻址驯服动态字节分块的硬件不规则性