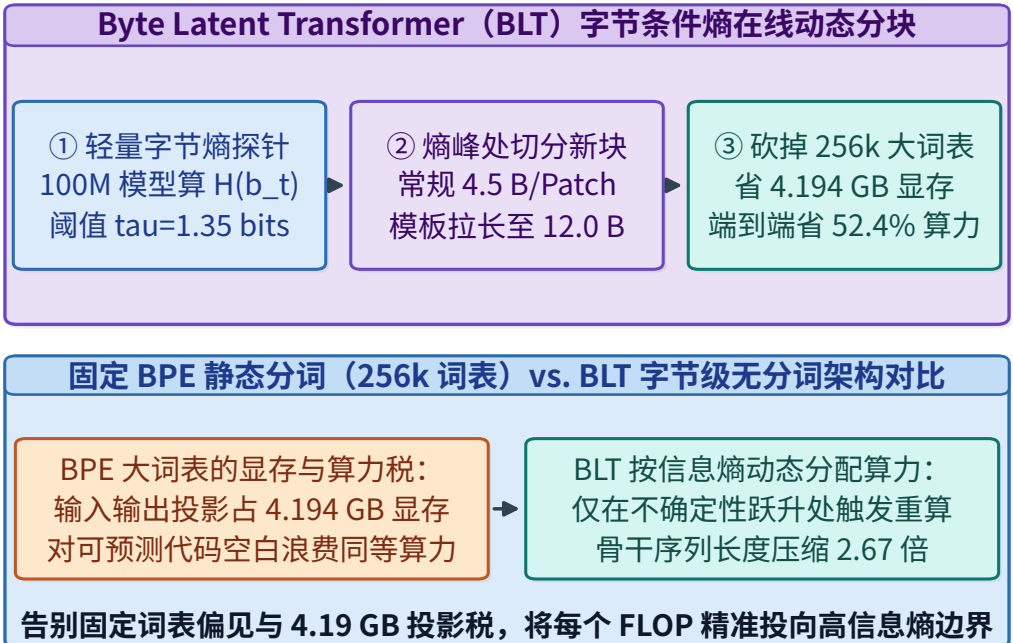
Byte Latent Transformer（BLT）字节条件熵在线动态分块
① 轻量字节熵探针
100M 模型算 H(b_t)
阈值 tau=1.35 bits
② 熵峰处切分新块
常规 4.5 B/Patch
模板拉长至 12.0 B
③ 砍掉 256k 大词表
省 4.194 GB 显存
端到端省 52.4% 算力
固定 BPE 静态分词（256k 词表）vs. BLT 字节级无分词架构对比
BPE 大词表的显存与算力税：
输入输出投影占 4.194 GB 显存
对可预测代码空白浪费同等算力
BLT 按信息熵动态分配算力：
仅在不确定性跃升处触发重算
骨干序列长度压缩 2.67 倍
告别固定词表偏见与 4.19 GB 投影税，将每个 FLOP 精准投向高信息熵边界