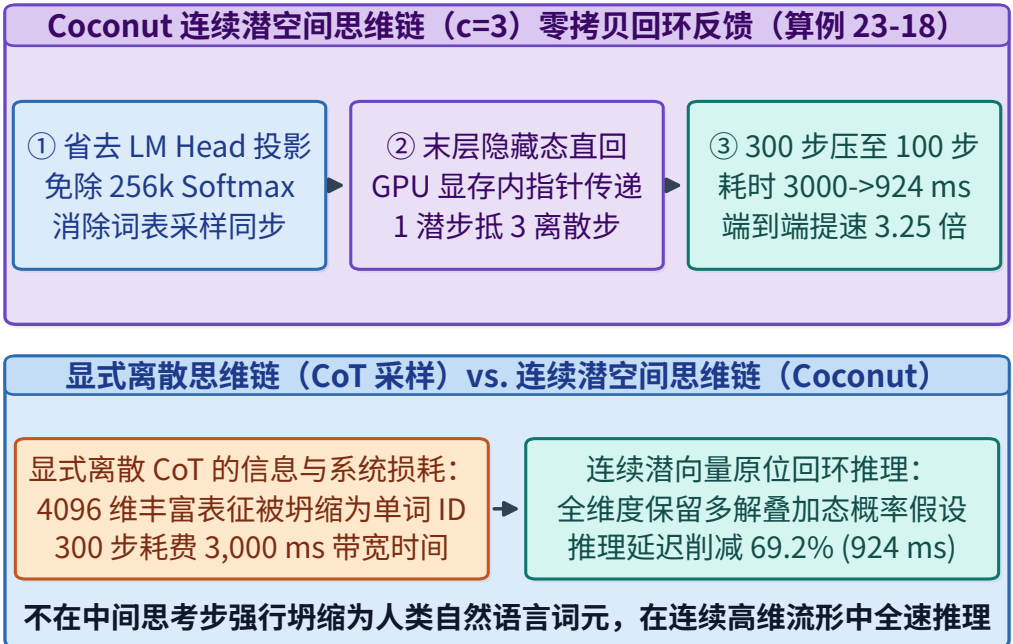
Coconut 连续潜空间思维链（c=3）零拷贝回环反馈（算例 23-18）
① 省去 LM Head 投影
免除 256k Softmax
消除词表采样同步
② 末层隐藏态直回
GPU 显存内指针传递
1 潜步抵 3 离散步
③ 300 步压至 100 步
耗时 3000->924 ms
端到端提速 3.25 倍
显式离散思维链（CoT 采样）vs. 连续潜空间思维链（Coconut）
显式离散 CoT 的信息与系统损耗：
4096 维丰富表征被坍缩为单词 ID
300 步耗费 3,000 ms 带宽时间
连续潜向量原位回环推理：
全维度保留多解叠加态概率假设
推理延迟削减 69.2% (924 ms)
不在中间思考步强行坍缩为人类自然语言词元，在连续高维流形中全速推理