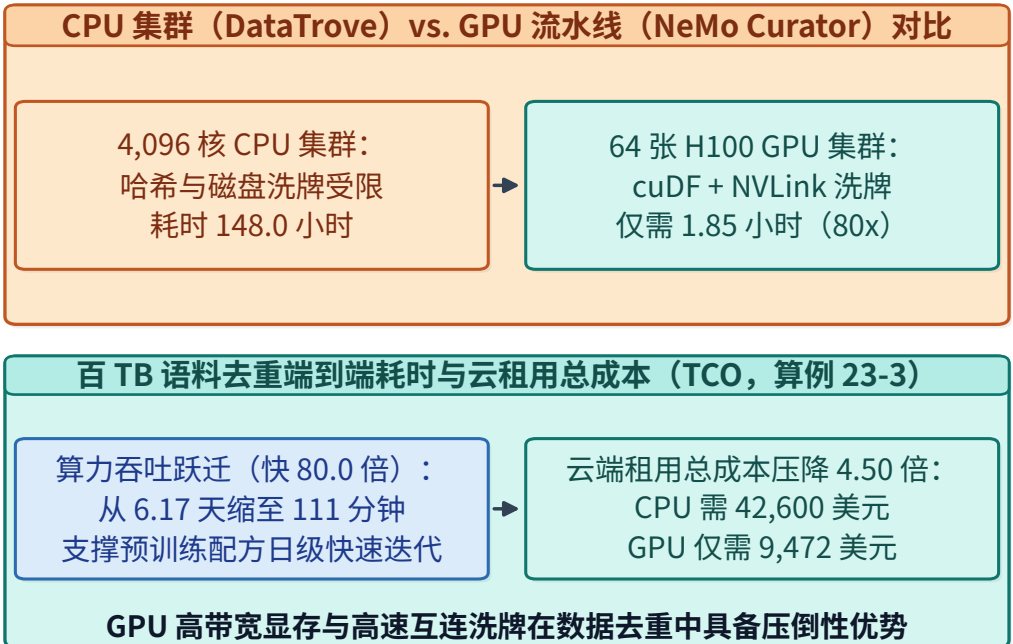
CPU 集群（DataTrove）vs. GPU 流水线（NeMo Curator）对比
4,096 核 CPU 集群：
哈希与磁盘洗牌受限
耗时 148.0 小时
64 张 H100 GPU 集群：
cuDF + NVLink 洗牌
仅需 1.85 小时（80x）
百 TB 语料去重端到端耗时与云租用总成本（TCO，算例 23-3）
算力吞吐跃迁（快 80.0 倍）：
从 6.17 天缩至 111 分钟
支撑预训练配方日级快速迭代
云端租用总成本压降 4.50 倍：
CPU 需 42,600 美元
GPU 仅需 9,472 美元
GPU 高带宽显存与高速互连洗牌在数据去重中具备压倒性优势