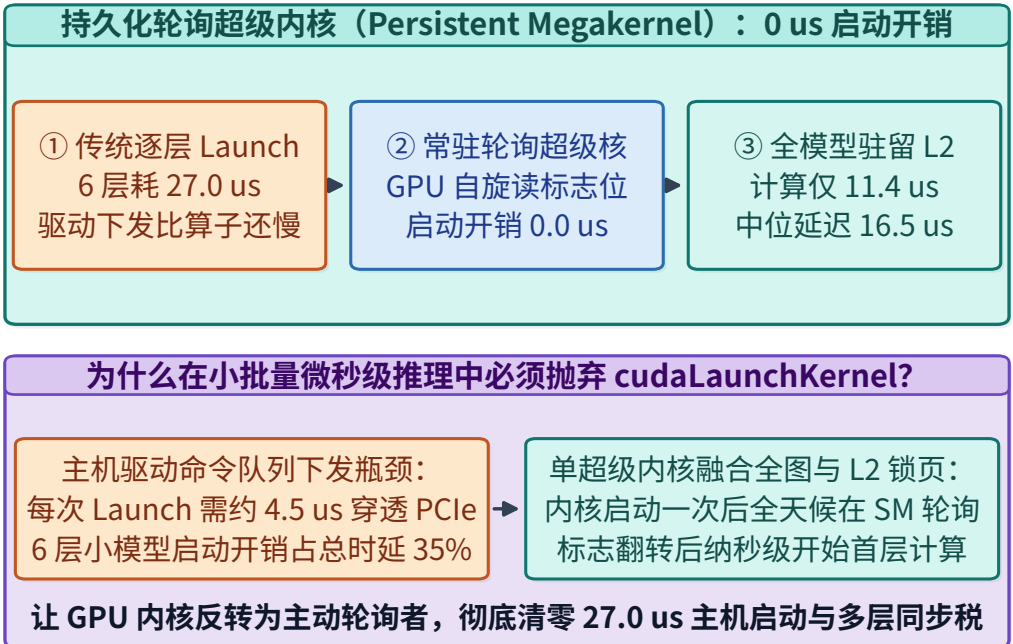
持久化轮询超级内核（Persistent Megakernel）：0 us 启动开销
① 传统逐层 Launch
6 层耗 27.0 us
驱动下发比算子还慢
② 常驻轮询超级核
GPU 自旋读标志位
启动开销 0.0 us
③ 全模型驻留 L2
计算仅 11.4 us
中位延迟 16.5 us
为什么在小批量微秒级推理中必须抛弃 cudaLaunchKernel?
主机驱动命令队列下发瓶颈：
每次 Launch 需约 4.5 us 穿透 PCIe
6 层小模型启动开销占总时延 35%
单超级内核融合全图与 L2 锁页：
内核启动一次后全天候在 SM 轮询
标志翻转后纳秒级开始首层计算
让 GPU 内核反转为主动轮询者，彻底清零 27.0 us 主机启动与多层同步税