算例 23-2：24×7 数字员工（≥30 tok/s）未优化基线成本对比

V4.1 Flash（1.30→6.42 GiB）
200K：B200 5.97 vs API 4.69
1M：B200 13.34 vs API 6.41 ($/M)

Kimi K3 基线（5.57→26.17 GiB）
200K：B300 145.13 vs 65.91
1M：B200 496.08 vs 125.19 ($/M)

性能归因审计（OPTIMIZATION-AUDIT）：区分架构代价与运行时伪影

伪影一：逐层启动调度 150 µs
93 层累加 13.95 ms/tok

伪影二：10% 重建 + 漏算 DSpark
摊入 9.18–9.26 ms/tok（占七成）

审计结论：未启用 MTP/DSpark 与算子融合的基线不能外推为架构劣势