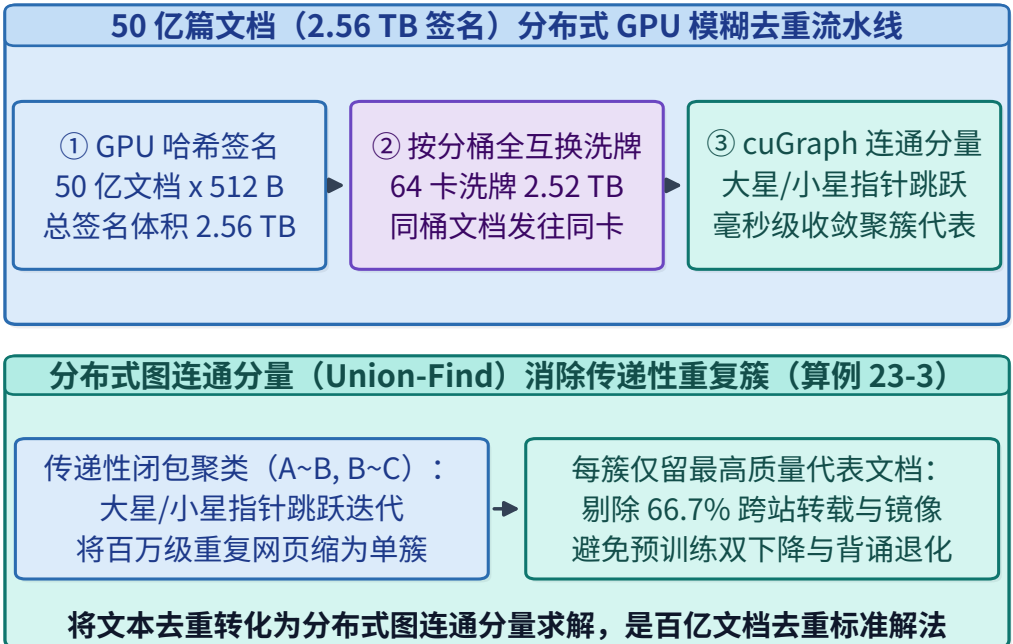
50 亿篇文档（2.56 TB 签名）分布式 GPU 模糊去重流水线
① GPU 哈希签名
50 亿文档 x 512 B
总签名体积 2.56 TB
② 按分桶全互换洗牌
64 卡洗牌 2.52 TB
同桶文档发往同卡
③ cuGraph 连通分量
大星/小星指针跳跃
毫秒级收敛聚簇代表
分布式图连通分量（Union-Find）消除传递性重复簇（算例 23-3）
传递性闭包聚类（A~B, B~C）：
大星/小星指针跳跃迭代
将百万级重复网页缩为单簇
每簇仅留最高质量代表文档：
剔除 66.7% 跨站转载与镜像
避免预训练双下降与背诵退化
将文本去重转化为分布式图连通分量求解，是百亿文档去重标准解法