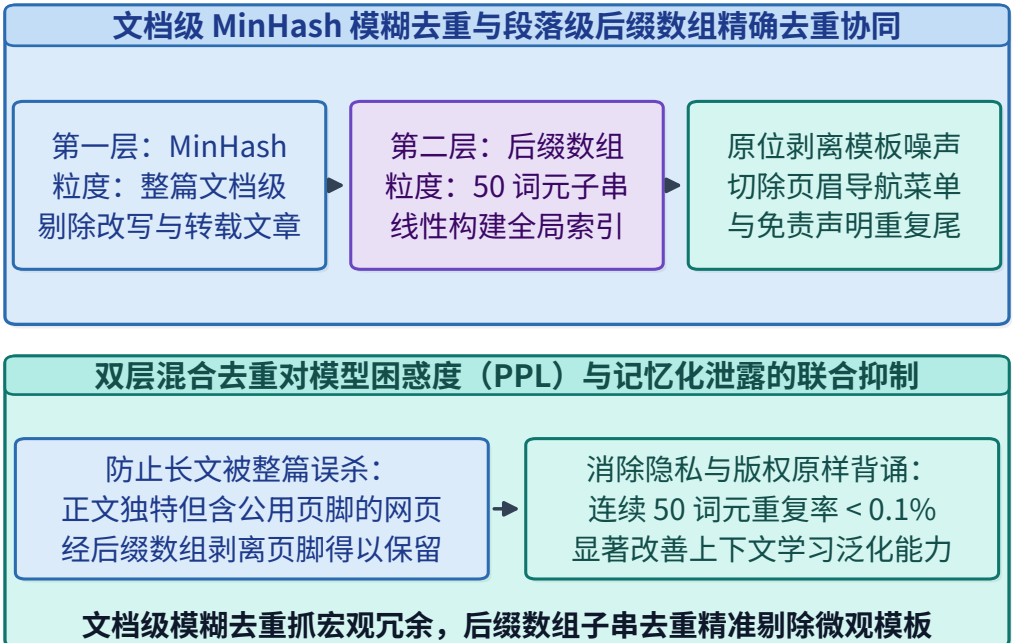
文档级 MinHash 模糊去重与段落级后缀数组精确去重协同
第一层：MinHash
粒度：整篇文档级
剔除改写与转载文章
第二层：后缀数组
粒度：50 词元子串
线性构建全局索引
原位剥离模板噪声
切除页眉导航菜单
与免责声明重复尾
双层混合去重对模型困惑度（PPL）与记忆化泄露的联合抑制
防止长文被整篇误杀：
正文独特但含公用页脚的网页
经后缀数组剥离页脚得以保留
消除隐私与版权原样背诵：
连续 50 词元重复率 < 0.1%
显著改善上下文学习泛化能力
文档级模糊去重抓宏观冗余，后缀数组子串去重精准剔除微观模板