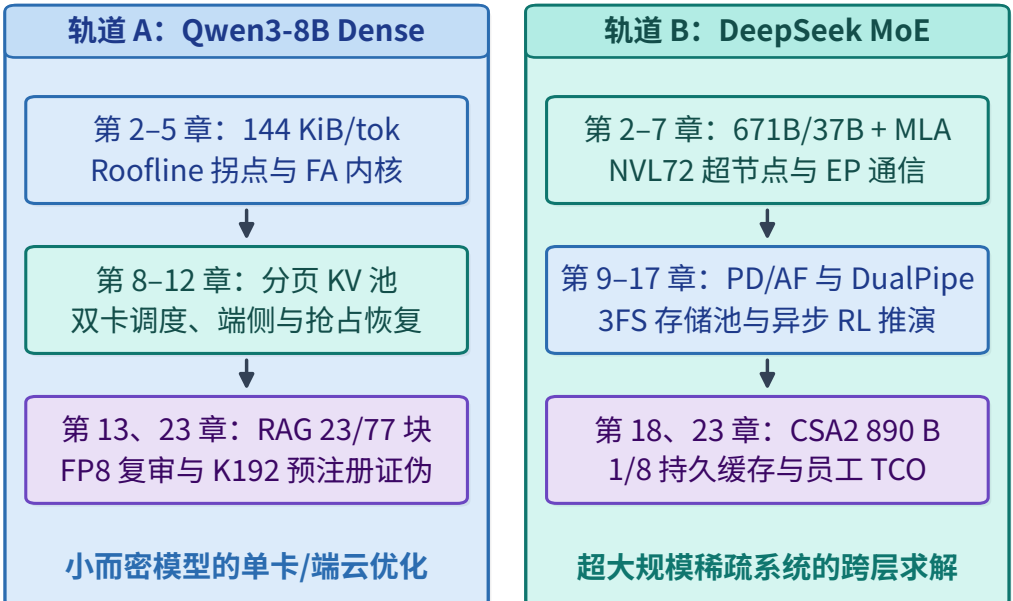
轨道 A：Qwen3-8B Dense
第 2–5 章：144 KiB/tok
Roofline 拐点与 FA 内核
第 8–12 章：分页 KV 池
双卡调度、端侧与抢占恢复
第 13、23 章：RAG 23/77 块
FP8 复审与 K192 预注册证伪
小而密模型的单卡/端云优化
轨道 B：DeepSeek MoE
第 2–7 章：671B/37B + MLA
NVL72 超节点与 EP 通信
第 9–17 章：PD/AF 与 DualPipe
3FS 存储池与异步 RL 推演
第 18、23 章：CSA2 890 B
1/8 持久缓存与员工 TCO
超大规模稀疏系统的跨层求解