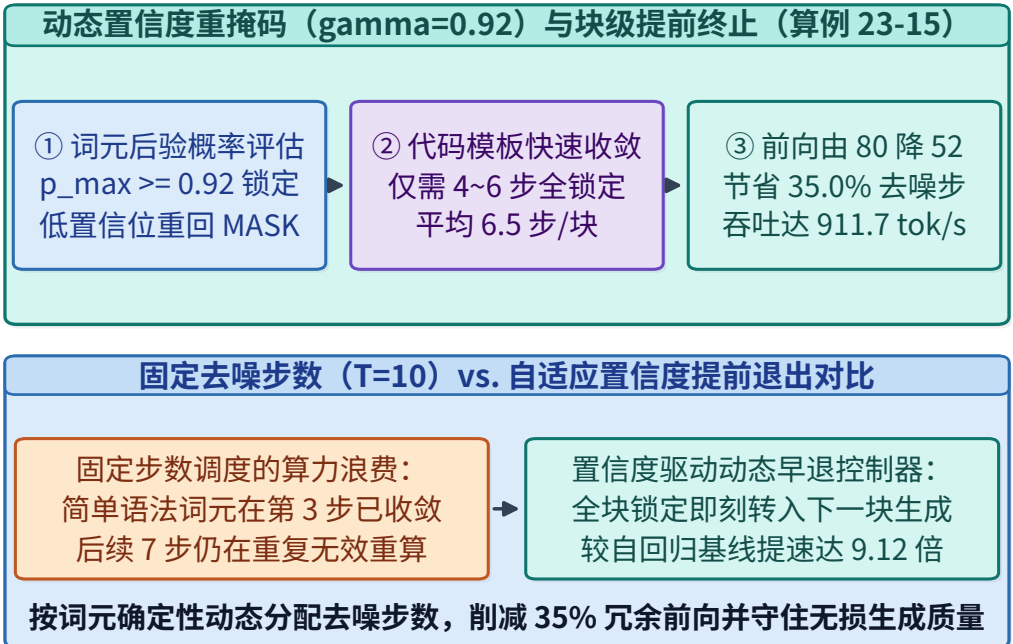
动态置信度重掩码（gamma=0.92）与块级提前终止（算例 23-15）
① 词元后验概率评估
p_max >= 0.92 锁定
低置信位重回 MASK
② 代码模板快速收敛
仅需 4~6 步全锁定
平均 6.5 步/块
③ 前向由 80 降 52
节省 35.0% 去噪步
吞吐达 911.7 tok/s
固定去噪步数（T=10）vs. 自适应置信度提前退出对比
固定步数调度的算力浪费：
简单语法词元在第 3 步已收敛
后续 7 步仍在重复无效重算
置信度驱动动态早退控制器：
全块锁定即刻转入下一块生成
较自回归基线提速达 9.12 倍
按词元确定性动态分配去噪步数，削减 35% 冗余前向并守住无损生成质量