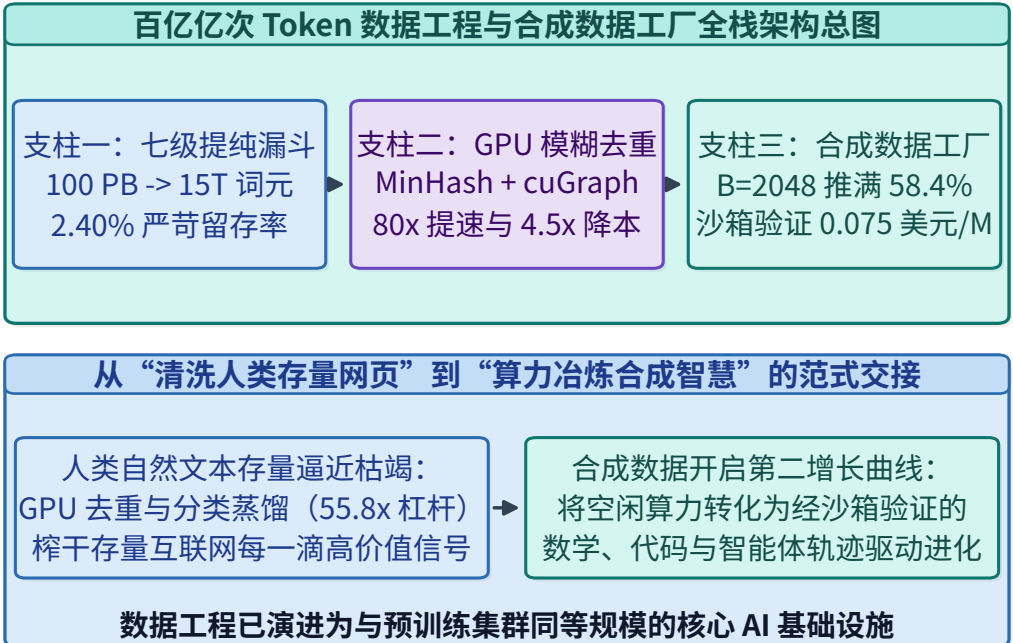
百亿亿次 Token 数据工程与合成数据工厂全栈架构总图
支柱一：七级提纯漏斗
100 PB -> 15T 词元
2.40% 严苛留存率
支柱二：GPU 模糊去重
MinHash + cuGraph
80x 提速与 4.5x 降本
支柱三：合成数据工厂
B=2048 推满 58.4%
沙箱验证 0.075 美元/M
从“清洗人类存量网页”到“算力冶炼合成智慧”的范式交接
人类自然文本存量逼近枯竭：
GPU 去重与分类蒸馏（55.8x 杠杆）
榨干存量互联网每一滴高价值信号
合成数据开启第二增长曲线：
将空闲算力转化为经沙箱验证的
数学、代码与智能体轨迹驱动进化
数据工程已演进为与预训练集群同等规模的核心 AI 基础设施