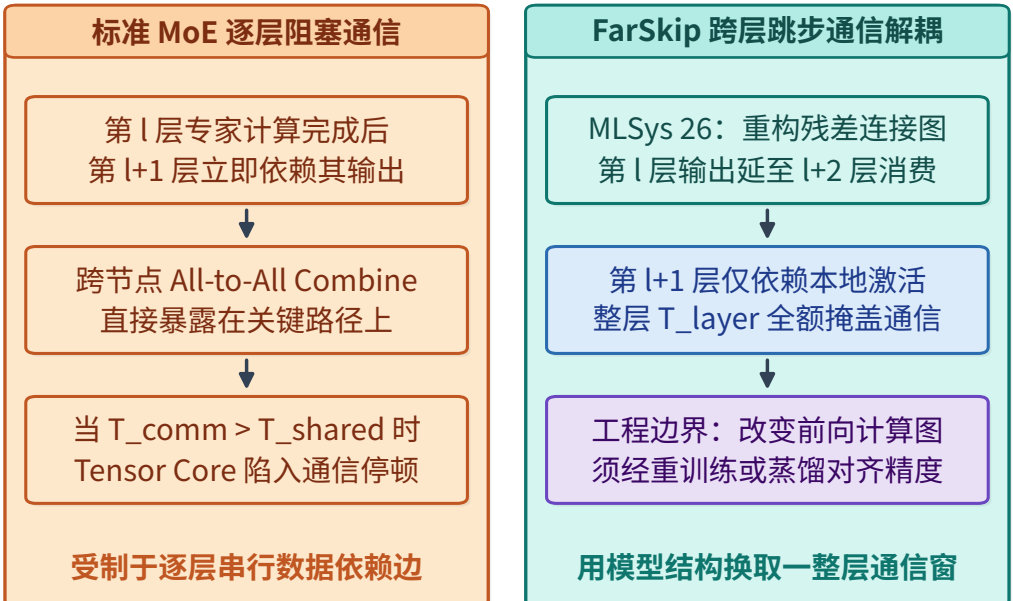
标准 MoE 逐层阻塞通信
第 l 层专家计算完成后
第 l+1 层立即依赖其输出
跨节点 All-to-All Combine
直接暴露在关键路径上
当 T_comm > T_shared 时
Tensor Core 陷入通信停顿
受制于逐层串行数据依赖边
FarSkip 跨层跳步通信解耦
MLSys 26：重构残差连接图
第 l 层输出延至 l+2 层消费
第 l+1 层仅依赖本地激活
整层 T_layer 全额掩盖通信
工程边界：改变前向计算图
须经重训练或蒸馏对齐精度
用模型结构换取一整层通信窗