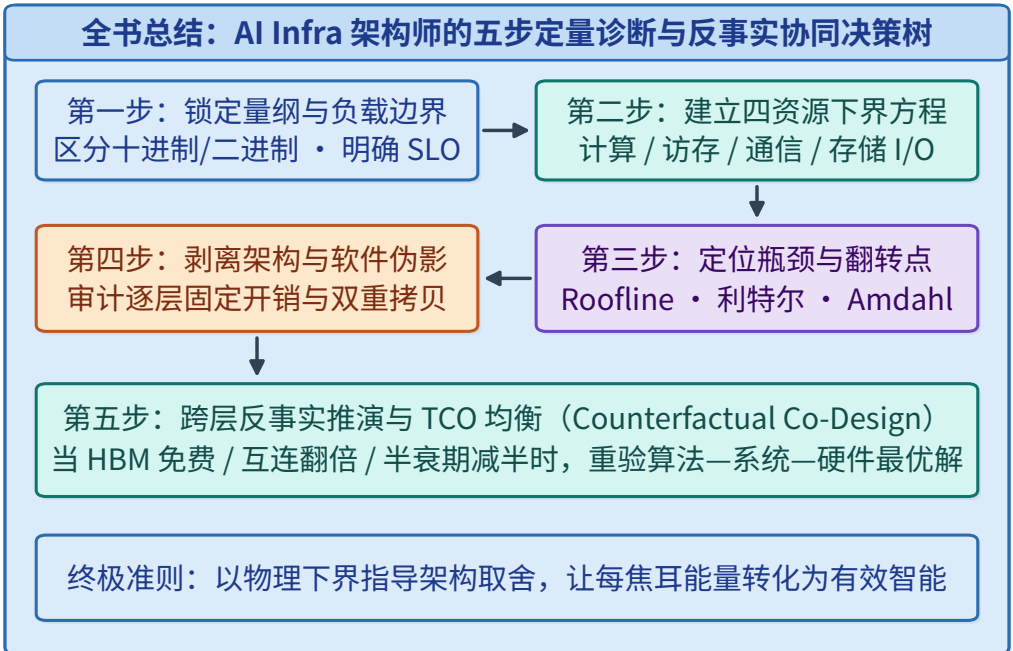
全书总结：AI Infra 架构师的五步定量诊断与反事实协同决策树
第一步：锁定量纲与负载边界
区分十进制/二进制 · 明确 SLO
第二步：建立四资源下界方程
计算 / 访存 / 通信 / 存储 I/O
第三步：定位瓶颈与翻转点
Roofline · 利特尔 · Amdahl
第四步：剥离架构与软件伪影
审计逐层固定开销与双重拷贝
第五步：跨层反事实推演与 TCO 均衡（Counterfactual Co-Design）
当 HBM 免费 / 互连翻倍 / 半衰期减半时，重验算法—系统—硬件最优解
终极准则：以物理下界指导架构取舍，让每焦耳能量转化为有效智能